



Un marco causal para medir el rendimiento clutch del jugador en fútbol de élite: el Causal Clutch Value (CCV)

*A Causal Framework for Measuring
Clutch Player Performance in Elite Football:
The Causal Clutch Value (CCV)*

Alumno: Jaime Oriol Goicoechea

Tutor: Pablo Sanzol

Email: joriolgo@gmail.com

Máster en Big Data Aplicado al Scouting en Fútbol

Sports Data Campus

Curso académico 2025-2026

Resumen

El rendimiento *clutch* es un concepto central del *scouting* moderno cuya cuantificación con rigor causal sigue sin resolverse en la literatura abierta. Los *rankings* públicos del jugador que aparece cuando importa parten de *eventing* puro, sin tracking sincronizado ni separación entre la contribución individual y el patrón colectivo del equipo. Este trabajo propone y evalúa el Causal Clutch Value (CCV), un marco causal que estima el efecto del *shock* emocional del gol sobre el desempeño del jugador en cuatro canales (ofensivo, defensivo, *off-ball* y físico) y tres contextos (post-gol a favor, post-gol en contra y proximidad de eliminación alta), residualizado contra el delta del propio equipo mediante *leave-one-out* en cada *shock*. La identificación causal se triangula con una estimación de diferencias-en-diferencias (DiD) *within-player* sobre la ventana de ± 10 minutos respecto al gol y un cuasi-experimento de *near-miss* apoyado en la cuasi-aleatoriedad del gol condicional al *expected goals* pre-disparo (xG); el efecto heterogéneo por jugador se condensa en un *Conditional Average Treatment Effect* (CATE) jerárquico bayesiano *multivariate* con correlaciones *cross-canal* y *priors* informados por *grades* humanos. El marco se aplica al Mundial Qatar 2022 con datos PFF FC como prueba técnica, único corpus público con tracking continuo de los 22 jugadores a 25 Hz sincronizado con el *eventing* y cobertura completa de fase eliminatoria.

El efecto poblacional medio es estadísticamente indistinguible de cero en los cuatro canales: el *shock* no mueve al jugador promedio. La señal *clutch* se localiza en la heterogeneidad individual y aparece bajo proximidad de eliminación alta, con cuatro jugadores significativos liderados por Kylian Mbappé (coeficiente +0,11 desviaciones estándar, probabilidad posterior 0,97). A nivel canal-específico, veintidós jugadores muestran efecto significativo en la celda ataque-tras-marcador —cinco al alza y diecisiete a la baja—, mientras que los agregados Remontador y Cerrojo quedan infra-identificados con $N = 172$ *shocks*. Hasta donde se ha podido verificar en la literatura abierta, el CCV es el primer marco que combina DiD *within-player* con cuasi-experimento *near-miss* a nivel jugador sobre un torneo eliminatorio, sobre cuatro canales y residualizado contra el bloque del equipo, con cuantificación de la incertidumbre por jugador.

Palabras clave: Fútbol · Inferencia causal · Modelos bayesianos jerárquicos · Rendimiento *clutch* · Datos de *tracking*.

Abstract

Clutch performance is a central concept in modern football scouting whose causal measurement remains an open problem. Public rankings of the player who shows up when it matters rely on pure event data, without synchronized tracking or separation between the individual contribution and the collective pattern of the team. This work proposes and evaluates the Causal Clutch Value (CCV), a causal framework that estimates the effect of the emotional shock of a goal on player performance across four channels (offensive, defensive, *off-ball* and physical) and three contexts (after scoring, after conceding and high elimination proximity), residualized against the team’s own delta via a *leave-one-out* scheme at each shock. Causal identification is triangulated through a within-player Differences-in-Differences (DiD) estimate over a ± 10 minute window around each goal and a *near-miss* quasi-experiment leveraging the conditional quasi-randomness of the goal given pre-shot *expected goals* (xG); the heterogeneous per-player effect is condensed into a hierarchical multivariate Bayesian Conditional Average Treatment Effect (CATE) with cross-channel correlations and priors informed by human grades. The framework is applied to the 2022 FIFA World Cup with PFF FC data as a technical proof of concept —the only public corpus with continuous 25 Hz tracking of all 22 players synchronized to the event stream and full knockout-stage coverage.

The population-average effect is statistically indistinguishable from zero across the four channels: the shock does not move the average player. The clutch signal is located in individual heterogeneity and appears under high elimination proximity, with four significant players led by Kylian Mbappé (coefficient $+0,11$ standard deviations, posterior probability 0,97). At the channel-specific level, twenty-two players show a significant effect in the post-scoring offense cell —five rising and seventeen declining—, while the Chasing and Protecting aggregates are under-identified at $N = 172$ shocks. To the best of our knowledge in the open literature, CCV is the first framework combining within-player DiD with a *near-miss* quasi-experiment at the player level over a knockout tournament, across four channels and residualized against the team block, with per-player uncertainty quantification.

Keywords: Football · Causal inference · Hierarchical Bayesian models · Clutch performance · Tracking data.

Agradecimientos

“El fútbol es como el ajedrez, pero sin dados.”

— Lukas Podolski

La paradoja de Podolski es la mía también desde que tengo memoria: un juego que se piensa como ajedrez y se decide en jugadas que ningún plan contempla. Llevo años intentando reconciliar las dos cosas —la convicción de que casi todo en el fútbol es medible y el respeto por lo que se sigue escapando a cualquier modelo— y este trabajo es un paso más en esa misma dirección. Si he podido darlo es porque hay personas detrás a las que les debo más de lo que cabe en una página.

A mis padres y a mi hermano Dani, por haber convertido el fútbol en parte de la conversación familiar desde el primer día y por dejarme transformar esa misma pasión en una carrera sin pedirme nunca explicaciones.

A David R. Sáez Ávila, por haber concebido y puesto en marcha el Máster en Big Data Aplicado al Scouting Deportivo en Sports Data Campus, un programa que abre una vía profesional real al cruce entre fútbol, datos y rigor analítico que hasta hace pocos años no existía en castellano.

A Pablo Sanzol, por tutorizar este trabajo y, sobre todo, por transmitir a lo largo del máster un nivel de exigencia y de valor docente que ha marcado la forma en la que entiendo el análisis aplicado al fútbol.

A Miguel Ángel del Barrio, por hablarme en su día de este máster y abrirme las puertas de un mundo profesional que sin esa conversación inicial difícilmente habría encontrado por mi cuenta.

Índice general

Resumen	i
Abstract	ii
Agradecimientos	iii
1 Introducción	1
1.1 Descripción del problema	1
1.2 Fundamento: el gol como shock emocional	2
1.3 Motivación	4
1.4 Organización de la memoria	6
2 Objetivos	7
2.1 Objetivo general	7
2.2 Objetivos específicos	7
3 Estado del arte	9
3.1 <i>Win Probability</i> bayesiana en fútbol	9
3.2 Valoración causal de acciones <i>on-ball</i>	10
3.3 Valoración defensiva individualizada	10
3.4 Valoración <i>off-ball</i> y control de espacio	11
3.5 Métricas físicas en torneo	12
3.6 Diferencias-en-diferencias con tratamientos heterogéneos	13
3.7 Cuasi-experimentos <i>near-miss</i> en deporte	14
3.8 Modelos de efecto heterogéneo bayesianos	14
3.9 Rendimiento <i>clutch</i> en fútbol	15
3.10 Espacio metodológico que cubre el CCV	16
4 Metodología	18
4.1 Marco metodológico	18
4.2 Marco teórico	21
4.2.1 Notación de los deltas individual, colectivo y relativo	22

4.2.2	Diferencias-en-diferencias <i>within-player</i>	23
4.2.3	Cuasi-experimento <i>near-miss</i>	23
4.2.4	CATE jerárquico bayesiano <i>multivariate</i>	24
4.3	Datos	25
4.4	Herramientas y tecnologías	26
4.5	Métricas de evaluación	27
4.6	Protocolo experimental	29
5	Desarrollo técnico	30
5.1	Extracción y preprocesado	30
5.2	Win Probability y <i>leverage</i>	31
5.3	Post-Shot <i>xG</i> y construcción del corpus de <i>near-miss</i>	32
5.4	Identificación de <i>shocks</i> y ventanas pre/post	35
5.5	Los cuatro canales del rendimiento	35
5.6	Identificación causal: DiD y <i>near-miss</i>	38
5.7	CATE jerárquico bayesiano <i>multivariate</i>	39
5.8	Ensamblaje del CCV y tabla <i>scout-facing</i>	40
6	Resultados	42
6.1	Calibración de los modelos predictivos	42
6.2	Identificación causal: pre-tendencias y sensibilidad	43
6.3	Efecto poblacional medio del shock	44
6.4	Heterogeneidad individual: el CATE jerárquico	45
6.5	Jugadores con respuesta significativa por contexto	46
6.6	Validación cualitativa contra los <i>grades</i> humanos PFF	50
7	Discusión	51
7.1	Qué sostienen los resultados	51
7.2	Qué no sostienen los resultados	52
7.3	Dónde funciona y dónde no funciona el CCV	53
7.4	Implicaciones operativas	54
8	Conclusiones	56
8.1	Conclusiones generales	56
8.2	Limitaciones	57
8.3	Líneas futuras	57
	Referencias bibliográficas	60
A	Visualizaciones complementarias	63

A.1	Fichas <i>scout-facing</i> adicionales	63
A.2	Vista por equipo: Francia	63
A.3	Verificación causal por <i>event-study</i>	64
A.4	Sensibilidad <i>HonestDiD</i> a violaciones de paralelismo	64
B	Limitaciones metodológicas en detalle	68
B.1	Implementación propia frente a librerías de referencia	68
B.2	Cobertura limitada al Mundial Qatar 2022	68
B.3	Sub-corpus de <i>near-miss</i> reducido	69
B.4	Qué <i>no</i> captura el CCV	69
C	Validaciones empíricas adicionales	70
C.1	Test de placebo	70
C.2	Análisis de potencia ex-ante	70
C.3	Estratificación por fase del torneo	71
C.4	Diagnósticos de calibración del PSxG	72
C.5	Auditoría de modelos predictivos del pipeline	72
D	Tablas <i>scout-facing</i> complementarias	74
D.1	Veintidós jugadores significativos en ofensivo-tras-marcas	74
D.2	<i>Dual-clutch top</i> : Remontador y Cerrojo simultáneamente	74
D.3	<i>Top pressure-clutch</i> del <i>bucket</i> atacante	75
D.4	Huella <i>clutch</i> colectiva por selección	76
E	Nota técnica: espejo del tracking en prórroga	77
E.1	Naturaleza de la inconsistencia	77
E.2	Mecanismo de detección automática	77
E.3	Ámbito de aplicación de la corrección	78
F	Repositorio público del proyecto	79
F.1	Qué contiene el repositorio	79
F.2	Cómo reproducir el trabajo	79
F.3	Licencia y acceso	79

Índice de figuras

4.1	Mapa conceptual del CCV.	18
4.2	<i>Pipeline</i> del CCV en seis fases.	19
4.3	Las cinco capas de identificación causal del CCV.	22
5.1	La cascada de tres <i>shocks</i> : España en el grupo E.	33
5.2	Superficie PPCF en el 2-2 de la final Argentina-Francia.	38
6.1	Curva de fiabilidad y descomposición de Brier del modelo PSxG.	42
6.2	Sensibilidad del ATE al horizonte pre/post.	44
6.3	Distribución del CATE individual por canal y contexto.	46
6.4	Panorama del torneo: Remontador frente a Cerrojo.	47
6.5	Ficha <i>scout-facing</i> de Kylian Mbappé.	48
6.6	Panorama del torneo: ataque tras marcar frente a ataque tras encajar. . . .	49
A.1	Ficha <i>scout-facing</i> de Lionel Messi.	63
A.2	Ficha <i>scout-facing</i> de Achraf Hakimi.	64
A.3	Ficha <i>scout-facing</i> de Marcelo Brozović.	65
A.4	Vista por equipo (Francia): Remontador frente a Cerrojo.	65
A.5	Vista por equipo (Francia): ataque tras marcar frente a ataque tras encajar. .	66
A.6	<i>Event-study</i> por minuto relativo al <i>shock</i>	66
A.7	Cotas <i>HonestDiD</i> sobre el ATE poblacional.	67

Índice de tablas

5.1	Tipologías del corpus de <i>near-miss</i>	34
5.2	Resumen de los cuatro canales del rendimiento.	36
6.1	Composición del corpus de <i>shocks</i> del torneo.	45
6.2	ATE del <i>shock</i> sobre el delta relativo al bloque, por canal y dirección. . . .	46
6.3	Jugadores significativos por celda y por umbral.	47
6.4	Jugadores con efecto <i>pressure-clutch</i> significativo.	48
6.5	Correlación de Spearman entre CCV y <i>grade</i> humano PFF.	50
C.1	Test de placebo sobre las ocho celdas canal-por-contexto.	70
C.2	Potencia ex-ante por celda canal-por-contexto.	71
C.3	ATE estratificado por fase del torneo.	71
C.4	Diagnósticos de calibración del modelo PSxG.	72
C.5	Auditoría de los modelos predictivos del <i>pipeline</i> frente a la literatura. . . .	73
D.1	Veintidós jugadores con respuesta significativa en ofensivo-tras-marcas. . .	75
D.2	<i>Dual-clutch top</i> : ranking combinado Remontador + Cerrojo.	75
D.3	<i>Top pressure-clutch</i> del <i>bucket</i> atacante (ATA).	76
D.4	Huella <i>clutch</i> colectiva por selección (<i>top-8</i>).	76

1 Introducción

1.1. Descripción del problema

El 18 de diciembre de 2022, en el estadio de Lusail, Argentina y Francia disputan la final del Mundial. El partido reúne en menos de dos horas el conjunto de *shocks* emocionales sobre los que trabaja esta memoria. Argentina marca el 1-0 al minuto 23 desde el punto de penalti, transformado por Messi, y el partido apenas cambia de tono: el bloque francés sigue jugando atrás y Argentina mantiene la circulación cómoda. Al minuto 36, Di María hace el 2-0; Francia no reacciona del todo y el primer tiempo se va al descanso con Argentina sin generar más peligro y con un campeón vigente incapaz de pasar del medio campo. El guion se mantiene durante los primeros treinta y cinco minutos del segundo tiempo, hasta que al minuto 80 Mbappé transforma un penalti y firma el 2-1. En los noventa y siete segundos que separan ese tanto del 2-2 —también de Mbappé, esta vez en jugada abierta tras pared con Thuram— Francia se hace dueña del partido y Argentina pierde el control. La prórroga vuelve a abrirse para Argentina con el 3-2 de Messi al minuto 108, hasta que Mbappé empata al 118 desde otro penalti y completa su *hat-trick*. La tanda decide el Mundial.

Lo que esa final condensa, y lo que cualquier aficionado reconoce sin necesidad de métrica, es que el fútbol es un deporte gobernado por emociones tanto como por táctica. La forma en la que un equipo celebra, sufre, se viene abajo o se rehace tras un gol es parte inseparable del juego y, a menudo, lo que define el resultado de los partidos grandes. La analítica deportiva moderna ha avanzado mucho en medir la parte táctica y técnica del rendimiento —valor de cada pase, expectativa de gol por disparo, control de espacio en cada *frame*— pero la dimensión emocional del juego, pese a su peso en la narrativa y en la decisión, sigue siendo una de las menos medidas por los marcos analíticos disponibles. Es ese hueco el que motiva el trabajo.

Cada uno de esos seis goles es un *shock* emocional con respuesta colectiva propia y no derivable del marcador. El 1-0 apenas movió el partido; el 2-0 no provocó la reacción esperable del campeón vigente; el 2-1 de Mbappé condensó en menos de dos minutos un cambio de tono del partido. El equipo ganador no siempre se cerró ni el perdedor siempre apretó: cada bloque respondió a cada gol de forma distinta, en función del minuto, de la cercanía de eliminación, del tono del partido hasta ese instante y de su tipología táctica. La respuesta colectiva al gol cambia de un equipo a otro y de un momento a otro del mismo partido, y condiciona después el rendimiento individual: cualquier intento de medir *clutch* a nivel jugador sin controlar por ese patrón colectivo termina mezclando dos señales distintas.

La fase de grupos del mismo torneo extiende el concepto. El último partido del grupo E —España contra Japón, en paralelo a Costa Rica contra Alemania— comprime en veinte minutos tres *shocks* encadenados sobre los jugadores españoles que ninguna acción propia genera: la proximidad de eliminación de España salta del 5 % al 68 % cuando Costa Rica se pone por delante de Alemania, y vuelve a bajar al 10 % cuando Alemania reacciona en el tramo final. La figura 5.1 del capítulo 5 reporta la cascada minuto a minuto.

Esa diferencia de reacción entre bloques obliga a separar dos preguntas *clutch* distintas. La primera es una pregunta de equipo: cómo reacciona el bloque tras un gol, a favor o en contra —si cierra atrás, sube líneas, presiona alto o se hunde—. La segunda es una pregunta de jugador: dentro de esa reacción colectiva, quién destaca individualmente por encima del bloque, quién queda por debajo y quién acompaña la inercia. El *scouting* moderno y el mercado de fichajes se han concentrado en la segunda mientras la median sin controlar la primera. Cuando un jugador rinde bien en partidos grandes, no es trivial separar si destaca él o si acompaña a un equipo que destaca.

La respuesta operativa hoy es que no se distingue con certeza. Los *rankings* públicos del jugador que aparece cuando importa —los *big-game players* de la prensa anglosajona, los *clutch performers* del *scouting* comercial— parten de *eventing* puro, sin contrafactual exógeno y sin separación entre la contribución individual y el patrón colectivo del equipo. El resultado es un mercado que paga sobreprecio por reputación *clutch* sin métrica objetiva, y un cuerpo técnico que decide cambios al minuto 75 protegiendo un 1-0 sobre intuición y experiencia. El trabajo conceptualmente más cercano, Bransen et al. (2019), mostró en MIT Sloan que con *eventing* puede ordenarse a los jugadores en categorías *choke* o *shine* dentro de *bins* de presión definidos a priori. Su métrica es descriptiva, opera sobre *eventing* sin tracking y no separa al jugador del patrón colectivo del equipo —las acciones *off-ball*, que son las que más se transforman tras un *shock* emocional, quedan fuera del análisis.

La pregunta abierta, por tanto, es si puede estimarse causalmente el rendimiento *clutch* del jugador residualizado contra el patrón colectivo de su bloque, sobre los cuatro canales del rendimiento —ofensivo, defensivo, *off-ball* y físico— y diferenciando entre los tres contextos de impacto emocional —post-gol a favor, post-gol en contra y cercanía de eliminación alta. Este trabajo defiende que sí, propone el marco para hacerlo y lo aplica al Mundial Qatar 2022.

1.2. Fundamento: el gol como shock emocional

El gol reúne tres propiedades que lo hacen útil como unidad de análisis de un shock emocional en fútbol. La primera es la frecuencia: en las grandes ligas europeas se anotan en media en torno a dos goles y medio por partido (Pappalardo et al., 2019), suficiente para acumular muestra a lo largo de un torneo y poco habitual como para que cada uno

conserve carga informativa. La segunda es la observabilidad: cada gol queda registrado con *timestamp* exacto y asociado a una secuencia de juego concreta, lo que permite definir sin ambigüedad la ventana anterior y posterior. La tercera es el carácter discreto del cambio que introduce: a diferencia de tiros, ocasiones o paradas, que el bloque atraviesa de forma gradual, el gol mueve el marcador en un instante puntual y con dirección conocida. A las tres se suma una cuarta más sustantiva: el gol es el único evento del fútbol que, por sí solo, cambia la inercia del partido de forma observable. El equipo que marca se siente respaldado y el equipo que encaja se reorganiza, y ese ajuste se traduce en patrones medibles —más presión, líneas más altas o más bajas, cambios de ritmo— en los minutos inmediatamente posteriores. Por eso el gol funciona como unidad natural de tratamiento causal sobre la respuesta del equipo y, dentro de ella, del jugador.

Esta unidad cubre dos de los tres contextos sobre los que el CCV mide respuesta individual —post-gol a favor y post-gol en contra—. El tercero es la proximidad de eliminación: cuanto más cerca está un equipo de quedar fuera del torneo, mayor es la carga emocional sobre cada acción aunque no haya un gol que la dispare. Estos tres contextos no agotan el concepto de *clutch* en sentido amplio. Un mediocampista que defiende un 1-1 en el minuto noventa de fase de grupos cuando los dos equipos están clasificados también está jugando un momento de presión competitiva —quiere ganar el partido— pero sin un *shock* emocional discreto ni proximidad de eliminación inminente. Ese tipo de presión queda fuera del alcance del marco. El CCV se restringe a momentos donde la emoción y la presión cruzan un umbral identificable a nivel de evento o de contexto; sin ese umbral, la identificación causal a nivel individual no es viable.

El efecto del gol sobre el comportamiento colectivo del equipo está documentado empíricamente. Konefał et al. (2024), sobre 278 partidos de la temporada 2022/23 de la Ekstraklasa polaca, miden cambios significativos en los patrones físicos del equipo —distancia recorrida y acciones de alta intensidad— en los cinco minutos previos al gol respecto a la línea base del partido, tanto cuando el equipo marca como cuando recibe. El análisis es a nivel de equipo y no responde si ese ajuste se reparte de forma homogénea entre los jugadores del bloque o si se concentra en una parte de ellos.

A nivel individual la respuesta al gol es heterogénea: dos jugadores con perfiles agregados similares pueden reaccionar en direcciones opuestas al mismo *shock*, algo que cualquier analista reconoce en la observación táctica y en el análisis post-partido. La cuantificación analítica disponible de esa heterogeneidad —discutida en §1.3— es descriptiva, no causal, y opera sobre *eventing* puro sin tracking ni separación entre el jugador y el patrón colectivo del equipo.

El *shock* del gol queda así medido a nivel de equipo y visible en su efecto colectivo, pero sin estimación causal a nivel jugador residualizada contra el bloque del propio equipo. La sección siguiente detalla por qué ese hueco metodológico es accesible hoy con los datos

abiertos disponibles; los capítulos posteriores formalizan el marco que lo aborda.

1.3. Motivación

La asimetría que justifica este trabajo es sencilla de plantear. El fútbol profesional genera hoy millones de eventos *tagged* por temporada —cada pase, cada disparo, cada recuperación— y decenas de modelos analíticos consolidados que los explotan para medir la dimensión técnica y táctica del rendimiento. La respuesta emocional del jugador a los *shocks* del partido, en cambio, sigue sin medirse causalmente a nivel individual sobre ningún corpus público. La propiedad existe —basta ver una final para reconocerla— pero el mercado, el cuerpo técnico y la prensa la juzgan sobre intuición y observación, no sobre métrica causal con identificación al nivel del jugador. Esta es la asimetría que el trabajo se propone reducir.

La pregunta *clutch* tiene además consecuencias económicas inmediatas. Un director deportivo que decide entre dos centrocampistas de precio similar —uno con reputación *clutch* en KO de Champions, el otro con perfil más estable pero sin antecedente de partidos grandes— toma esa decisión sobre intuición y observación, sin métrica causal que la oriente. Lo mismo vale para la gestión de cambios en el banquillo: al minuto 75 protegiendo un 1-0 en cuartos de Copa, el cuerpo técnico elige entre el mediocentro X —con minutos de cerrojo en partidos grandes— y el jugador Y —con mejor base estadística pero sin antecedente en ese contexto— sobre la misma base. La propiedad se reconoce como existente sin que pueda cuantificarse.

La literatura analítica reciente ha avanzado en cada pieza del problema por separado, pero no en su composición sobre un mismo marco. La valoración causal de acciones *on-ball* está madura desde el marco *Valuing Actions by Estimating Probabilities* (VAEP) y su familia —*atomic*-VAEP, *Expected Threat* (xT), y el *Expected Possession Value* (EPV). La valoración defensiva individualizada se ha desarrollado con estimadores específicos en los últimos cinco años. La valoración *off-ball* cuenta con modelos de control de espacio y peligro contrafactual ya consolidados. La capa física es trazable a nivel jugador desde los protocolos sobre tracking *broadcast* en torneo. La identificación causal moderna se ha enriquecido con estimadores robustos para tratamientos pulsados con efectos heterogéneos y con cotas de sensibilidad frente a violaciones de tendencias paralelas.

Ninguna de esas piezas se había encadenado al nivel jugador-minuto sobre un torneo eliminatorio, con identificación causal dual y residualizado contra el bloque colectivo. El antecedente físico ya citado de Konefal et al. (2024) opera a nivel de equipo y solo cubre el canal físico. Morgans et al. (2025) operan por mitades de partido sobre estados de marcador agregados en Premier League, sobre treinta y tres jugadores y dos temporadas, también con métricas físicas únicamente. Bransen et al. (2019), también ya citado, trabaja sobre

eventing sin tracking ni condicionamiento causal. Ninguno separa al jugador del patrón colectivo, triangula con un contrafactual exógeno ni cubre los cuatro canales conjuntamente sobre un torneo eliminatorio con prórroga.

Lo que abre la puerta técnica a hacerlo es la liberación del dataset PFF FC del Mundial Qatar 2022 (PFF FC, 2024). En septiembre de 2024, PFF FC publicó en abierto los sesenta y cuatro partidos del torneo con *eventing*, tracking a 25 Hz sincronizado con los eventos, presión individual etiquetada y *grades* humanos por evento. Es el único corpus público que combina los tres ingredientes estructurales que la pregunta exige simultáneamente: tracking continuo *full-pitch* de los 22 jugadores a 25 Hz, sincronización con el *eventing* y cobertura completa de fase eliminatoria con prórroga incluida. StatsBomb 360 cubre los *freeze-frames* en eventos puntuales sobre Eurocopas y *Bundesliga*, pero no aporta tracking continuo de los 22 jugadores entre eventos, que es lo que el cálculo del *pitch control* y el atributo *off-ball* exigen. PFF añade además *grades* humanos por evento, que el marco aprovecha como *prior* informativo del CATE jerárquico cuando están disponibles; este ingrediente enriquece la regularización y habilita una validación externa cualitativa, pero no es estructural: el marco corre sobre corpus sin *grades* sustituyendo el *prior* informativo por uno débil, sin afectar la identificación causal.

Más allá de la disponibilidad de datos, el Mundial es además el escenario con la mayor exigencia emocional posible en el fútbol. La representación nacional, la eliminación a partido único sin ida y vuelta, las semanas concentradas en un país distinto al propio y la frecuencia cuatrienal del torneo concentran sobre cada acción una carga competitiva que ningún corpus de liga reproduce con la misma intensidad. Esta convergencia —disponibilidad técnica más intensidad emocional máxima— explica que el Mundial sea el banco de pruebas del trabajo y no una elección oportunista. La portabilidad del marco a otros corpus con estructura equivalente —ligas domésticas con clasificación europea o descenso en juego, eliminatorias de *Champions League* con ida y vuelta— queda como dimensión de extensión y se desarrolla en el capítulo de líneas futuras.

Junto a la disponibilidad de datos, la maquinaria causal moderna está también madura para abordar la pregunta. La identificación del efecto del *shock* requiere triangulación, dado que una sola estrategia es vulnerable a sesgos no observados; para que el resultado se sostenga hace falta que dos estrategias independientes coincidan en signo y magnitud. La primera es una estimación de diferencias-en-diferencias (DiD) *within-player* sobre la ventana de ± 10 minutos respecto al gol, robustecida con los estimadores modernos para tratamientos pulsados. La segunda es un cuasi-experimento de *near-miss*: dentro de los disparos con xG pre-disparo comparable (la calidad técnica conocida *antes* de ver dónde acaba el balón, distinta del Post-Shot xG que evalúa la trayectoria final), el hecho de que el balón entre o no entre se aproxima a azar; el contraste entre la respuesta post-gol y la respuesta post-*near-miss* aísla el efecto del *shock* del rendimiento intrínseco del bloque que

generó el disparo. Si las dos estrategias coinciden, el efecto causal se considera robusto; si divergen, la divergencia se reporta como cota superior del *confounding* no controlado.

El marco propuesto en este trabajo —el Causal Clutch Value (CCV)— encadena estos elementos y entrega una métrica *scout-facing* por jugador, por canal y por contexto, con cuantificación de la incertidumbre vía intervalos de credibilidad bayesianos. La contribución central es metodológica: el marco es portable a cualquier dataset con la misma estructura mínima (*events* + tracking + cobertura KO completa); los *grades* humanos por evento son un ingrediente deseable cuando están disponibles —aportan *prior* informativo al CATE y validación externa— pero no son condición necesaria. La aplicación al Mundial Qatar 2022 funciona como prueba técnica de concepto, no como objetivo en sí. Cualquier liberación abierta futura de *eventing* + tracking sobre un torneo de fase eliminatoria permitirá recalibrar el *pipeline* CCV sin cambios estructurales.

1.4. Organización de la memoria

El presente capítulo introduce la pregunta de investigación y separa el *clutch* del bloque del *clutch* del jugador relativo al bloque.

El capítulo 2 fija el objetivo general y los seis objetivos específicos del trabajo.

El capítulo 3 sitúa el marco en el estado del arte sobre los nueve bloques que lo configuran y cierra identificando el *gap* específico que el CCV cubre.

El capítulo 4 formaliza la metodología: notación de los deltas individual y colectivo, especificación del estimador DiD y del cuasi-experimento *near-miss*, formulación del CATE jerárquico bayesiano *multivariate* y protocolo experimental.

El capítulo 5 documenta el desarrollo técnico del *pipeline* de principio a fin, desde la extracción de los datos hasta el ensamblaje final del CCV en una tabla *scout-facing*.

El capítulo 6 reporta los resultados: validación interna del marco y efectos a nivel poblacional e individual sobre el corpus.

El capítulo 7 discute qué demuestran y qué no demuestran los datos, dónde funciona el marco y dónde no, y las implicaciones operativas para *scouting*, fichajes, preparación de partidos eliminatorios y gestión de cambios.

El capítulo 8 cierra con las conclusiones generales, las limitaciones declaradas y las líneas futuras de extensión.

La bibliografía sigue en formato APA séptima edición. Los anexos amplían el detalle de limitaciones, validaciones empíricas adicionales, visualizaciones complementarias y una nota técnica sobre el espejo del tracking en prórroga.

2 Objetivos

2.1. Objetivo general

Proponer, implementar y evaluar el Causal Clutch Value (CCV), un marco causal que estima el efecto del *shock* emocional del gol sobre el rendimiento individual del jugador residualizado contra el patrón colectivo de su propio equipo, sobre cuatro canales del rendimiento —ofensivo, defensivo, *off-ball* y físico— y tres contextos emocionales —post-gol a favor, post-gol en contra y proximidad de eliminación alta—. La identificación causal se triangula con diferencias-en-diferencias *within-player* y un cuasi-experimento de *near-miss*; el efecto heterogéneo por jugador se condensa en un *Conditional Average Treatment Effect* (CATE) jerárquico bayesiano *multivariate*. El marco se aplica al Mundial Qatar 2022 con datos PFF FC como prueba técnica.

2.2. Objetivos específicos

Cada objetivo específico responde a una pregunta de investigación (RQ) y se mapea sobre un bloque concreto del *pipeline* de implementación descrito en el capítulo 5.

OE1 (RQ1) — *Backbone* temporal. Construir la capa que modula continuamente el contexto del *shock*. Estima la *Win Probability* (WP) bayesiana por minuto sobre corpus fuera del torneo objetivo y recalibrada al Mundial Qatar 2022, deriva el *leverage* —la sensibilidad de la probabilidad de ganar a un gol marginal— y la proximidad de eliminación por equipo y minuto. Estas tres señales son los moduladores continuos que alimentan al modelo CATE.

OE2 (RQ2) — *Shocks* y *near-misses*. Identificar los *shocks* emocionales del torneo (gol a favor y gol en contra), calcular las ventanas pre/post de ± 10 minutos por jugador y la composición *leave-one-out* del bloque colectivo, y construir el corpus complementario de *near-misses* sobre cinco tipologías —palo o travesaño, fuera de juego milimétrico, parada del portero sobre disparo de *Post-Shot xG* (PSxG) alto, despeje en línea de gol y no-gol confirmado por tecnología— como contrafactual exógeno para la estrategia causal de *near-miss*.

OE3 (RQ3) — Cuatro canales del rendimiento. Implementar los cuatro canales sobre PFF FC con el estimador de referencia del estado del arte (*State of the Art*, SOTA) de cada capa: *atomic*-VAEP y *un-xPass* en el canal ofensivo; VDEP estricto, *exPress* y

atribución al defensor más cercano *frame-level* en el canal defensivo; OBSO y C-OBSO sobre tracking 25 Hz en el canal *off-ball*; protocolo Bradley con residual bayesiano *multivariate* por jugador en el canal físico. Las agregaciones se producen por jugador-minuto y por jugador-*shock*-ventana con cálculo *leave-one-out* del bloque colectivo.

OE4 (RQ4) — Triangulación causal. Estimar el efecto causal del *shock* mediante dos estrategias independientes sobre el delta relativo al bloque. La primera es una DiD *within-player* con efectos fijos, contrastada contra los estimadores modernos para tratamientos pulsados robustos a heterogeneidad. La segunda es un AIPW (*Augmented Inverse Probability Weighting*) doblemente robusto con *cross-fitting* sobre el corpus de *near-miss*, comparado internamente contra DML (*Double/Debiased Machine Learning*) *Partially Linear Regression*, el DR-learner (doblemente robusto) y un RDD (*Regression Discontinuity Design*) local-lineal sobre xG .

OE5 (RQ5) — CATE jerárquico y tabla *scout-facing*. Estimar el efecto heterogéneo por jugador con un CATE jerárquico bayesiano *multivariate* sobre los cuatro canales conjuntamente, con correlaciones *cross*-canal modeladas mediante una previa Lewandowski–Kuwrowicka–Joe (LKJ) y *priors* informados por *grades* humanos PFF, sampleado con *Hamiltonian Monte Carlo* y el *sampler* No-U-Turn (NUTS) en cuatro cadenas. Ensamblar la tabla *scout-facing* canónica del CCV con un jugador por fila, tres índices agregados (Remontador, Cerrojo, *Pressure Response*), vector resumen por canal, *rankings* por posición y *bucket* posicional, y *flags* de incertidumbre.

OE6 (RQ6) — Validación intrínseca y causal. Validar empíricamente el marco desde dos ángulos. La validación intrínseca cubre la calibración del modelo PSxG —curva isotónica, descomposición de Brier, errores de calibración esperado y máximo (ECE, *Expected Calibration Error*; MCE, *Maximum Calibration Error*) y área bajo la curva ROC (*Receiver Operating Characteristic*, AUC) en *holdout* WC22— y la correlación entre los canales algorítmicos y los *grades* humanos PFF por jugador-evento. La validación causal cubre el placebo *within-series* con corrección Benjamini-Hochberg, el análisis de potencia, la sensibilidad de la ventana a cinco horizontes, la estratificación fase de grupos frente a eliminatoria y la comparación cruzada del DiD *within-player* con el ATT (*Average Treatment effect on the Treated*) del cuasi-experimento *near-miss*.

3 Estado del arte

El marco que propone este trabajo se construye sobre piezas metodológicas que se han desarrollado de forma independiente en la última década. Este capítulo recorre el estado del arte de cada una de ellas en el orden en que aparecen en el *pipeline*: la espina dorsal temporal de *Win Probability*, los cuatro canales de valoración del rendimiento —*on-ball*, defensivo, *off-ball* y físico—, la maquinaria de identificación causal con diferencias-en-diferencias modernas, el cuasi-experimento *near-miss*, los modelos de efecto heterogéneo bayesianos y los antecedentes específicos sobre rendimiento *clutch* en fútbol. El capítulo cierra identificando con precisión el espacio metodológico que ocupa el CCV.

3.1. *Win Probability* bayesiana en fútbol

La estimación continua de la probabilidad de ganar un partido se ha consolidado en deportes de marcador frecuente, pero llegó tarde al fútbol por la baja frecuencia de gol y por la dificultad de capturar las variaciones contextuales del partido sin saturar el modelo de ruido. El primer modelo bayesiano publicado para fútbol con calibración honesta es el de Robberechts et al. (2021): un esquema logit ordinal de tres clases —victoria local, empate y victoria visitante— sobre los noventa minutos del partido, con interceptos tiempo-variables modulados por una previa de paseo aleatorio que regulariza la suavidad temporal de las probabilidades. Las *features* cubren diferencia de gol, diferencia de tarjetas rojas, diferencia de Elo y un proxy de *momentum* ofensivo reciente medido como la diferencia de tiros en los diez minutos anteriores. El modelo se entrena sobre miles de partidos de las cinco grandes ligas europeas y produce probabilidades calibradas que pueden interpretarse directamente como expectativa de ganar dadas las condiciones observadas.

Klemp et al. (2021) muestran un resultado relevante para cualquier análisis posterior: una vez condicionado el modelo en las cuotas de mercado previas al partido, los indicadores in-play —goles incluidos— añaden valor predictivo solo marginal sobre el desenlace final. La implicación operativa es que cualquier marco que busque detectar efectos del gol sobre el rendimiento debe superar un suelo de ruido alto, dado que la cuota inicial absorbe buena parte de la varianza posterior del partido. Por eso la capa de *Win Probability* (WP) del CCV no busca predecir el resultado mejor que el mercado: busca proporcionar moduladores continuos del contexto del *shock* —*leverage*, definido como la sensibilidad de la probabilidad de ganar a un gol marginal, y la proximidad de eliminación— para condicionar adecuadamente la respuesta del jugador.

Lo que el estado del arte no resuelve, y este trabajo aborda, es la cobertura completa del calendario de un torneo eliminatorio: el modelo de Robberechts et al. cubre los noventa

minutos de regulación pero no incorpora prórroga ni tanda de penaltis, ambas inherentes a la fase eliminatoria. La espina dorsal temporal del CCV extiende la WP a prórroga mediante una tasa de gol con distribución de Poisson y a tanda mediante un modelo paramétrico, recalibrando el conjunto sobre la fase de grupos del Mundial Qatar 2022 mediante *temperature scaling*.

3.2. Valoración causal de acciones *on-ball*

La valoración cuantitativa de acciones individuales con balón ha madurado en la última década. La línea principal es la propuesta de *Valuing Actions by Estimating Probabilities* (VAEP), de Decroos et al. (2019): cada acción *on-ball* recibe un valor proporcional al cambio que produce en la probabilidad de marcar y en la probabilidad de conceder un gol en las próximas N acciones, estimadas con modelos de *gradient boosting* sobre *features* posicionales y contextuales del estado de juego. VAEP separa la contribución individual del rendimiento agregado del equipo, lo que la convierte en candidata natural a *outcome* de un análisis causal pre/post-*shock*.

Fernández et al. (2021) extienden la lógica al marco continuo del *Expected Possession Value* (EPV): la posesión se modela como un proceso de decisión de Markov sobre acciones de pase, conducción y disparo, con cada componente estimado por separado mediante redes convolucionales sobre datos de tracking. La descomposición modular del EPV permite, para una secuencia de juego dada, separar el impacto de la decisión del impacto de la ejecución, e identificar el valor añadido por acciones contrafactuales no observadas.

La extensión más reciente del eje *on-ball* es *un-xPass*, de Robberechts et al. (2023): introduce la *Creative Decision Rating* (CDR), que descuenta el valor VAEP de un pase exitoso por la probabilidad previa de que ese pase concreto fuera la elección obvia dado el estado de juego. La métrica captura el componente de creatividad pura del jugador con balón —elegir y ejecutar una opción inesperada que resulta valiosa— y completa la valoración *on-ball* como producto de decisión y ejecución. El canal ofensivo del CCV combina ambas piezas: *atomic*-VAEP como valoración del resultado de cada acción atómica de SPADL (*Soccer Player Action Description Language*), y *un-xPass* como *rating* de creatividad en la decisión de pase.

3.3. Valoración defensiva individualizada

La valoración defensiva ha sido históricamente más difícil que la valoración ofensiva, en parte porque las acciones defensivas exitosas son escasas y dispersas en el espacio-tiempo del partido. La propuesta seminal sobre tracking sincronizado es VDEP (*Valuing Defense by Estimating Probabilities*), de Toda et al. (2022): una métrica análoga a VAEP que mide

$$\text{VDEP}(a, s) = P(\text{recuperación}_N \mid a, s) - C \cdot P(\text{ataque}_N \mid a, s),$$

donde a es la acción defensiva, s es el estado de juego, N el horizonte de acciones futuras y C pondera el coste de conceder un ataque frente al valor de recuperar el balón. Toda y colaboradores calibran C sobre la J-League y muestran que VDEP separa equipos de calidad defensiva alta y baja de forma consistente con la clasificación. La métrica asigna valor a la acción defensiva concreta, lo que permite agregarla por jugador, pero deja fuera la presión espacial sin acción explícita en el *eventing* y la contribución de los defensores próximos al balón sin intervención directa registrada.

Para la individualización al frame del defensor, el estado del arte combina dos esquemas complementarios. El primero es la atribución *frame-level* al defensor más cercano al balón, un esquema consolidado en la literatura aplicada sobre tracking que reparte el crédito defensivo por cada acción ofensiva del rival al defensor más próximo en el frame del evento, con signo negativo cuando la acción atacante es exitosa —el defensor más cercano carga con el coste— y positivo cuando falla. El esquema captura la presencia espacial del defensor incluso en frames sin acción defensiva explícita reflejada en el *eventing*. El segundo es *exPress* (Lee et al., 2025): una cabeza dedicada que estima la probabilidad de recuperación del balón en los cinco segundos siguientes a un evento de presión etiquetado por el proveedor, alimentada por *features* de *eventing* alineadas al tracking a 25 Hz. Es la versión moderna del *rating* de presión a nivel jugador y distingue la presión efectiva de la presión performativa.

El canal defensivo del CCV combina los tres *building blocks* —VDEP estricto, *exPress* y la atribución al defensor más cercano *frame-level*— sobre los datos PFF FC del Mundial Qatar 2022. La aportación específica del trabajo no reside en ninguno de los estimadores individuales, sino en su orquestación sobre ventanas pre/post-*shock* con residualización contra el bloque colectivo del propio equipo.

3.4. Valoración *off-ball* y control de espacio

La valoración *off-ball* aprovecha el tracking sincronizado para cuantificar el valor del movimiento sin balón, el componente del juego que el *eventing* puro no observa. La propuesta seminal es *Off-Ball Scoring Opportunities* (OBSO), de Spearman (2018): un modelo físico que descompone la probabilidad de gol desde cada posición del campo en producto de tres factores,

$$\text{OBSO}(r, t) = \text{PPCF}(r, t) \cdot T(r, t) \cdot S(r),$$

donde $\text{PPCF}(r, t)$ es la probabilidad de que el equipo atacante controle el balón en la

posición r en el instante t (*Potential Pitch Control Field*), $T(r, t)$ es la probabilidad de que el balón llegue a esa posición desde el frame actual y $S(r)$ es la expectativa de gol estática desde r . El control del balón se modela con un esquema de *pitch control* basado en tiempo-hasta-interceptar con velocidad máxima y tiempo de reacción por jugador, lo que permite calcular, para cada *frame*, una superficie continua de oportunidad de gol *off-ball* sobre el campo entero.

La extensión contrafactual es C-OBSO, de Teranishi et al. (2022): para cada jugador en cada *frame*, se predice su trayectoria contrafactual mediante una red neuronal de tipo *graph variational recurrent* y se calcula el OBSO que habría obtenido si en lugar de moverse se hubiera quedado en su posición previa. La diferencia entre OBSO observado y OBSO contrafactual atribuye al jugador el valor añadido por su movimiento —una métrica directa de inteligencia espacial.

El canal *off-ball* del CCV aplica OBSO con un cálculo vectorizado del *pitch control* sobre los sesenta y cuatro partidos del Mundial Qatar 2022 a 25 Hz, y deriva C-OBSO como diferencia entre la oportunidad observada y la contrafactual con el jugador quieto en su posición previa. El factor $T(r, t)$ de tiempo de llegada del balón se aproxima con un núcleo gaussiano respecto a la simulación física exacta del modelo seminal por restricciones de cómputo, simplificación documentada en el desarrollo metodológico del canal.

3.5. Métricas físicas en torneo

El protocolo físico de referencia para el Mundial Qatar 2022 es el de Bradley (2024): sobre tracking TRACAB a 25 Hz de los sesenta y cuatro partidos del torneo, define zonas de intensidad —Z4 (≥ 20 km/h) y Z5 (≥ 25 km/h)— y vincula la distancia recorrida en estas zonas con eventos tácticos concretos —recuperaciones, transiciones y entradas al último tercio. Las medias a nivel de equipo del torneo —en torno a 108 km de distancia total, 9 km en Z4 y 2,3 km en Z5— son la referencia canónica de comparabilidad para cualquier análisis físico sobre este corpus.

Sobre cómo evolucionan los patrones físicos en torno al gol, Konefał et al. (2024) documentan sobre 278 partidos de la temporada 2022/23 de la Ekstraklasa polaca que la distancia recorrida y las acciones de alta intensidad cambian de forma significativa en los cinco minutos previos al gol respecto a la línea base del partido, tanto cuando el equipo marca como cuando recibe. Morgans et al. (2025), sobre treinta y tres jugadores y dos temporadas de la *Premier League*, identifican variaciones análogas por mitades de partido en función del estado del marcador. Ambos trabajos operan a nivel de equipo o sobre métricas físicas exclusivamente, sin separar al jugador del bloque y sin extender el análisis a los canales tácticos.

El canal físico del CCV residualiza la distancia recorrida, los segundos en alta velocidad

(umbral 19,8 km/h, consistente con la literatura sobre tracking en torneo) y el número de *sprints* (umbral 25 km/h) contra una línea base personal del jugador modulada por la curva temporal del minuto. La residualización se estima mediante un modelo bayesiano jerárquico que descuenta tanto el estado físico individual como el efecto de cansancio agregado del partido, separando la componente decisional —lo que el jugador *aprieta* dentro de sus posibilidades— de la componente física —lo que el jugador *puede*.

3.6. Diferencias-en-diferencias con tratamientos heterogéneos

La identificación causal del efecto de un tratamiento pulsado sobre una unidad observada repetidamente en el tiempo se aborda canónicamente con diferencias-en-diferencias (DiD), que compara el cambio post-tratamiento de la unidad tratada con el cambio del grupo de control en el mismo intervalo. La versión clásica de DiD asume efectos homogéneos del tratamiento entre unidades y a través del tiempo, supuesto que la literatura econométrica reciente ha mostrado restrictivo cuando los tratamientos son escalonados o producen efectos heterogéneos.

Sun y Abraham (2021) muestran que la regresión clásica de *event-study* contamina los coeficientes promedio con efectos cruzados entre cohortes de tratamiento, y proponen un estimador de interacciones que aísla el efecto medio del tratamiento por cohorte y horizonte. Borusyak et al. (2024) reformulan el problema como un esquema de imputación contrafactual sobre las celdas no tratadas y derivan el estimador eficiente bajo identificación robusta a heterogeneidad y a paneles desbalanceados. Rambachan y Roth (2023) cierran el frente proporcionando cotas de sensibilidad explícitas: si la asunción de tendencias paralelas se relaja a una restricción de suavidad sobre las desviaciones plausibles, el efecto causal estimado se acompaña de un intervalo que cuantifica cuánto puede moverse el coeficiente ante violaciones acotadas de la asunción.

El DiD *within-player* del CCV aplica el estimador clásico con efectos fijos por jugador y por minuto de partido como ATE (*Average Treatment Effect*) poblacional, lo contrasta contra los estimadores de Sun y Abraham y Borusyak et al. como verificación de robustez y reporta las cotas *HonestDiD* de Rambachan y Roth como rango de sensibilidad. La aportación del trabajo no es ninguno de los tres estimadores: es su aplicación al panel jugador-minuto sobre un torneo eliminatorio con el gol como tratamiento pulsado y discreto.

3.7. Cuasi-experimentos *near-miss* en deporte

El cuasi-experimento *near-miss* explota una identidad unidad-tratada-unidad-control en la que la asignación del tratamiento es aproximadamente aleatoria condicional a una variable de calidad técnica. Gauriot y Page (2019) formalizan el diseño en deporte: para tiros con *expected goals* (xG) pre-disparo comparable, el hecho de que el balón entre o no se aproxima a un sorteo. La calidad técnica del disparo y el contexto previo quedan condicionados por el xG ; lo que separa el gol del *near-miss* es la trayectoria final del balón —el viaje de centímetros que define palo o gol, fuera de juego milimétrico o adelantamiento legal, parada o no-parada del portero.

La aplicación del diseño *near-miss* al fútbol no se había encadenado todavía sobre tracking sincronizado en un torneo eliminatorio. El CCV construye un corpus complementario de *near-misses* sobre cinco tipologías —palo o travesaño, fuera de juego milimétrico, parada del portero sobre un disparo con *Post-Shot xG* (PSxG) alto, despeje en línea de gol y no-gol confirmado por la tecnología de gol— y los empareja con goles efectivamente marcados de calidad técnica comparable, evaluada por un modelo PSxG calibrado fuera del torneo. La estrategia causal de *near-miss* complementa el DiD: si los dos métodos coinciden en signo y magnitud del efecto, el efecto causal del gol se considera robusto al *confounding* no observado.

3.8. Modelos de efecto heterogéneo bayesianos

La estimación del efecto heterogéneo por unidad —el *Conditional Average Treatment Effect* (CATE)— se ha abordado en la literatura econométrica reciente con esquemas no paramétricos. Hahn et al. (2020) proponen el *Bayesian Causal Forest* (BCF): una descomposición jerárquica del modelo de *outcome* en una función pronóstica del control y una función de tratamiento del efecto, con regularización separada que evita confundir el efecto del tratamiento con la variación pronóstica de las covariables. El BCF muestrea cadenas de Markov sobre la geometría de árboles y produce posteriores conjuntas del CATE por unidad y de la varianza por unidad, con cuantificación de la incertidumbre individual sin recurrir a *bootstrap*.

En fútbol, la aplicación bayesiana jerárquica más cercana es la de Iapteff et al. (2025): un modelo de efectos mixtos sobre xG con efectos aleatorios por jugador y por posición, transferencia entre competiciones e interpretabilidad mediante valores SHAP (*SHapley Additive exPlanations*). Iapteff y colaboradores muestran que la estructura jerárquica con *priors* informativos ofrece mejores estimaciones de efectos individuales que un modelo agregado, especialmente cuando el tamaño de muestra por jugador es pequeño —condición habitual en fútbol de élite, donde incluso las estrellas acumulan pocos eventos del mismo

tipo por temporada.

El modelo CATE del CCV es jerárquico bayesiano *multivariate* sobre los cuatro canales conjuntamente, con correlaciones *cross*-canal modeladas mediante una previa Lewandowski–Kurowicka–Joe (LKJ) y *priors* informados por los *grades* humanos PFF pre-torneo. Las cadenas se muestrean con *Hamiltonian Monte Carlo* (HMC) y el *sampler* No-U-Turn (NUTS) sobre cuatro réplicas independientes. La aportación específica respecto al estado del arte es el carácter *multi-outcome* de la estimación —no un CATE por canal por separado sino un CATE conjunto sobre los cuatro canales con estructura de correlación aprendida— y la transferencia de información entre canales a través de la previa LKJ, que permite que canales con menor señal hereden información de los canales correlacionados con más muestra.

3.9. Rendimiento *clutch* en fútbol

El concepto de rendimiento *clutch* en deporte tiene una definición operativa clásica en Otten (2009): el aumento de rendimiento bajo presión. El trabajo experimental de Otten sobre tiros libres en baloncesto identifica el rasgo de *control percibido* como predictor robusto del rendimiento bajo presión y el hábito de *reinvertir atención* en la tarea como predictor de *choke*. La definición se ha mantenido como anclaje conceptual en la psicología del deporte y en *analytics*; lo que ha cambiado en la última década es la posibilidad de medirla causalmente con datos de tracking en lugar de mediante cuestionarios autoinformados.

El antecedente analítico más cercano al CCV en fútbol es Bransen et al. (2019): sobre *eventing* puro, los autores definen *bins* de presión a priori —tramos del partido por estado de marcador y minuto— y ordenan a los jugadores en categorías *choke* y *shine* según el cambio en su contribución VAEP por noventa minutos entre los *bins* de presión alta y baja. La métrica es descriptiva, opera sin tracking sincronizado ni condicionamiento causal, y no separa al jugador del patrón colectivo del equipo. Los autores identifican casos concretos —Mahrez como ejemplo de *shine*, Ghezzal como ejemplo de *choke*— pero reconocen que la atribución es relativa al bloque del equipo en cada minuto y no aísla la contribución individual.

Konefał et al. (2024) y Morgans et al. (2025), ya citados en el canal físico, son los antecedentes a nivel equipo y por mitades de partido respectivamente; ninguno cubre el nivel jugador-minuto ni triangula con un contrafactual exógeno. La literatura analítica sobre *clutch* en fútbol queda por tanto en estado descriptivo o agregado: la propiedad se ordena, pero no se estima causalmente, y la separación entre la contribución individual y el patrón colectivo del equipo es un asunto pendiente.

Esa separación es la que el CCV aborda combinando tres mecanismos que la literatura previa no había encadenado sobre un mismo corpus: residualización *leave-one-out* de

la respuesta individual contra el bloque del propio equipo en cada *shock*, efectos fijos jugador-*shock* en el DiD *within-player* para absorber la heterogeneidad invariante del jugador, y cuasi-experimento *near-miss* como triangulación independiente apoyada en la cuasi-aleatoriedad del gol condicional al xG pre-disparo. La sección 4.2 formaliza esta combinación.

3.10. Espacio metodológico que cubre el CCV

Las nueve piezas anteriores existen por separado y están razonablemente maduras. Lo que no existe en la literatura aplicada es su composición. El CCV ocupa el espacio definido por seis requisitos simultáneos:

1. Definición de los *shocks* emocionales sobre una espina dorsal temporal de WP bayesiano calibrada a la cobertura completa de un torneo eliminatorio, incluyendo regulación, prórroga y tanda de penaltis.
2. Cuantificación de la respuesta del jugador en los cuatro canales del rendimiento con el estimador de referencia de cada capa —*atomic*-VAEP y *un-xPass* en ofensivo, VDEP con *exPress* y atribución al defensor más cercano *frame-level* en defensivo, OBSO y C-OBSO en *off-ball*, y protocolo Bradley en físico.
3. Residualización de la respuesta individual contra el patrón colectivo del propio equipo mediante un *leave-one-out* al frame de cada *shock*.
4. Triangulación causal entre un DiD *within-player* robustecido contra heterogeneidad y un cuasi-experimento *near-miss* apoyado en la cuasi-aleatoriedad del gol condicional al *pre-shot xG*.
5. Estimación del efecto heterogéneo por jugador con un CATE jerárquico bayesiano *multivariate* sobre los cuatro canales conjuntamente y *priors* informados por los *grades* humanos PFF.
6. Entrega de una métrica *scout-facing* por jugador, canal y contexto con cuantificación de la incertidumbre individual mediante intervalos de credibilidad bayesianos.

Para que esta composición sea aplicable hace falta un corpus público con *eventing* sincronizado a tracking continuo *full-pitch* de los 22 jugadores a alta frecuencia (25 Hz como referencia) y cobertura completa de fase eliminatoria. El Mundial Qatar 2022 con datos PFF FC (PFF FC, 2024) es el primer corpus público que reúne esa combinación, y el motivo por el que el banco de pruebas del trabajo es ese torneo y no otro. PFF añade además *grades* humanos por evento, que el marco aprovecha como *prior* informativo del

CATE jerárquico y como validación externa cualitativa; este ingrediente es deseable pero no estructural, y el marco es portable a cualquier futuro corpus con la misma estructura mínima —con o sin *grades*—, sustituyendo en su ausencia el *prior* informativo por uno débil.

4 Metodología

Este capítulo formaliza la metodología del CCV en seis bloques: el *pipeline* en seis fases (§4.1), la notación de los deltas individual y colectivo y las especificaciones formales de los dos estimadores causales y del modelo CATE jerárquico bayesiano *multivariate* (§4.2), los tres corpus utilizados y el régimen de separación entre entrenamiento y evaluación (§4.3), la pila tecnológica (§4.4), las métricas con las que se evalúa cada capa (§4.5) y el protocolo experimental que rige la producción de los resultados del capítulo siguiente (§4.6).

4.1. Marco metodológico

Antes del detalle técnico del *pipeline*, esta sección fija la lógica conceptual sobre la que opera el CCV. La figura 4.1 la resume en tres ejes encadenados: el tipo de *shock* emocional (gol a favor, gol en contra o proximidad de eliminación), si el jugador rompe del bloque o se mueve con él, y si la reacción es positiva o negativa. La descomposición se proyecta finalmente sobre los cuatro canales del rendimiento (ofensivo, defensivo, *off-ball* y físico). Este diagrama responde al **qué mide** el CCV; el *pipeline* de la figura 4.2 responde al **cómo lo computa**.




Figura 4.1. Mapa conceptual del CCV.

El *pipeline* se ejecuta como un grafo dirigido acíclico de seis fases. Cada fase consume el cache de la anterior y deposita un cache intermedio que las fases posteriores reutilizan, lo que permite recomputar cualquier capa sin reejecutar las anteriores y facilita la reproducibilidad numérica cuando se preserva el entorno de cómputo (versiones de librerías, semillas

y *backend* JAX/CUDA). La figura 4.2 sintetiza la composición de las seis fases y las anotaciones metodológicas que conectan unas con otras.




Figura 4.2. Pipeline del CCV en seis fases.

Fase 1. Extracción y preprocesado. Los eventos PFF FC en formato JSON y el tracking a 25 Hz en formato *JSON Lines* comprimido se extraen a parquet con tipos anidados *lossless*. Sobre ese cache se calculan tres normalizaciones de base que el resto del *pipeline* asume: la dirección de ataque de cada equipo por período (para normalizar coordenadas de tracking respecto al sentido del ataque), la línea temporal de goles válidos (excluyendo goles anulados y tantos de la tanda de penaltis) y los minutos jugados por jugador y partido. Una corrección técnica relevante: en algunos partidos PFF FC entrega el frame de tracking rotado 180° respecto al frame del *eventing* en los períodos de prórroga; el preprocesado detecta esta inconsistencia comparando la dirección de ataque registrada con la posición del portero en tracking y des-rota cuando procede. La corrección se aplica de forma transparente en cualquier consulta que mezcle coordenadas con dirección de ataque.

Fase 2. Backbone temporal. La probabilidad de ganar el partido se estima por minuto vía un modelo bayesiano logit ordinal de tres clases con interceptos tiempo-variables, entrenado por *Stochastic Variational Inference* (SVI) sobre los corpus externos (*open dataset* Wyscout 2017/18 (Pappalardo et al., 2019) y StatsBomb *open data* (StatsBomb, 2024) fuera del Mundial Qatar 2022). La recalibración al Mundial se realiza mediante *temperature scaling* sobre la fase de grupos, ajustando un único parámetro escalar de

temperatura por desplazamiento de distribución. La cobertura se extiende a prórroga mediante una tasa de gol con distribución de Poisson estimada sobre prórrogas históricas y a tanda de penaltis mediante un modelo paramétrico. De la WP se derivan dos moduladores continuos: el *leverage*, definido como la sensibilidad de la probabilidad de ganar a un gol marginal, y la proximidad de eliminación por equipo y minuto. En la fase de grupos, la proximidad de eliminación se calcula por simulación Monte Carlo del grupo completo dado el partido actual y los partidos restantes; en la fase eliminatoria, coincide con la propia WP desplazada según la perspectiva del equipo.

Fase 3. *Shocks* y *near-misses*. Cada gol válido del torneo se etiqueta como *shock* emocional con dos perspectivas —GOAL_FOR para el equipo que marca y GOAL_AGAINST para el equipo que encaja— y se calcula la ventana pre/post de ± 10 minutos por jugador en campo, con *flags* explícitos de truncamiento por inicio o fin de partido, solapamiento con otro *shock*, sustitución dentro de la ventana y *shock* en tiempo extra. El corpus complementario de *near-miss* se construye sobre cinco tipologías —palo o travesaño, fuera de juego milimétrico, parada del portero sobre disparo de PSxG alto, despeje en línea de gol y no-gol confirmado por la tecnología de gol— con umbrales pre-registrados sobre el xG pre-disparo entre 0,15 y 0,85 para asegurar comparabilidad técnica con los goles marcados. El modelo PSxG que evalúa la calidad técnica del disparo se entrena fuera del Mundial sobre eventos StatsBomb *open data* (StatsBomb, 2024) (Euro 2020, Euro 2024 y Bundesliga 23/24) con *features* de *end-location* tridimensional, presión defensiva y 360 *freeze-frames*, y se calibra por regresión isotónica.

Fase 4. Cuantificación del rendimiento en cuatro canales. Cada canal se estima con el *building block* de referencia descrito en el capítulo 3. El canal ofensivo combina *atomic*-VAEP, entrenado con CatBoost sobre la representación *atomic*-SPADL de los eventos, y *un-xPass* como *rating* de creatividad en la decisión de pase. El canal defensivo combina VDEP estricto (cabeza dedicada de probabilidad de recuperación y de ser atacado en las próximas acciones SPADL), *exPress* como probabilidad de recuperación en cinco segundos post-presión y atribución al defensor más cercano al balón *frame-level*. El canal *off-ball* aplica OBSO y C-OBSO sobre tracking a 25 Hz con cálculo vectorizado del *pitch control*. El canal físico aplica el protocolo Bradley sobre velocidades suavizadas con filtro Butterworth de fase cero, cap a 11 m/s preservando dirección, y residualiza la respuesta del jugador contra una línea base personal modulada por la curva temporal del minuto mediante un modelo bayesiano jerárquico estimado por SVI. Cada canal produce dos agregaciones: por jugador-minuto (panel para DiD) y por jugador-*shock*-ventana con cálculo *leave-one-out* del bloque colectivo del propio equipo (panel para AIPW y CATE).

Fase 5. Identificación causal y CATE jerárquico. El efecto causal del *shock* se estima mediante dos estrategias independientes. La primera es una diferencias-en-diferencias *within-player* con efectos fijos por jugador-*shock* y por minuto relativo al *shock*, contrastada contra los estimadores de Sun y Abraham (2021) y Borusyak et al. (2024) y robustecida con las cotas *HonestDiD* de Rambachan y Roth (2023). La segunda es un AIPW doblemente robusto con *cross-fitting* sobre el corpus de *near-miss*, complementado con *Partially Linear Regression* (PLR), *DR-learner* y un RDD local-lineal sobre la discontinuidad en *xG*. El efecto heterogéneo por jugador se condensa en un CATE jerárquico bayesiano *multivariate* sobre los cuatro canales conjuntamente, con correlaciones *cross-canal* por dirección del *shock* y *priors* informados por los *grades* humanos PFF pre-torneo.

Fase 6. Ensamblaje *scout-facing*. La capa final ensambla la tabla canónica del CCV con un jugador por fila a partir de la posterior del CATE: tres índices agregados (Remontador post-GA, Cerrojo post-GF y *Pressure Response* continuo), vector resumen por canal, ocho celdas canal-por-contexto con media posterior, intervalo de credibilidad y probabilidad posterior, *rankings* por posición granular y por *bucket* posicional, y *flags* de incertidumbre. Sobre esta tabla se construyen los *rankings scout-facing* y las tablas auxiliares (*top-10* por posición, *dual-clutch top*, agregación por selección) que constituyen el *output* final del trabajo.

4.2. Marco teórico

La identificación causal del CCV a nivel individual descansa sobre cinco capas que operan conjuntamente y que ninguna de ellas, por separado, aislaría el efecto del *shock* sobre el jugador del movimiento colectivo de su equipo. La figura 4.3 resume la composición: cada capa retira un confusor distinto y el estimador del CCV emerge únicamente cuando las cinco operan en secuencia.

La primera es el contraste temporal pre/post del mismo jugador en el mismo partido, que cancela su nivel basal de rendimiento como sujeto. La segunda son los efectos fijos por par jugador-*shock* en el DiD, que absorben rasgos invariantes del jugador en ese contexto concreto. La tercera es la residualización *leave-one-out* contra el bloque del propio equipo en el instante del *shock*, que sustrae el empuje colectivo del equipo y deja solo la desviación idiosincrásica del jugador respecto a sus compañeros. La cuarta es el cuasi-experimento *near-miss* sobre el corpus de disparos con *xG* pre-disparo comparable, que aporta variación cuasi-aleatoria en la ocurrencia del *shock* y rompe la endogeneidad asociada a que los goles los marquen los equipos que ya iban dominando el partido. La quinta es el AIPW con *cross-fitting*, que controla los *confounders* observables —minuto de partido, diferencia de marcador, fuerza del rival y fase del torneo— bajo doble robustez. Si falta cualquiera de las




Figura 4.3. Las cinco capas de identificación causal del CCV.

cinco capas el efecto del equipo se confunde con el del jugador; con las cinco juntas, lo que el estimador recupera es la respuesta propia del jugador, descontado el patrón colectivo del bloque.

4.2.1. Notación de los deltas individual, colectivo y relativo

Sea i un jugador, s un *shock* ocurrido en el minuto t_s del partido y k un canal del rendimiento. Para cada par (i, s) con i en campo en el instante t_s , se define la media del canal k en la ventana posterior y en la ventana anterior al *shock* como

$$\bar{Y}_{i,s,k}^{\text{post}} = \frac{1}{|\mathcal{W}^{\text{post}}|} \sum_{t \in \mathcal{W}^{\text{post}}} Y_{i,t,k}, \quad \bar{Y}_{i,s,k}^{\text{pre}} = \frac{1}{|\mathcal{W}^{\text{pre}}|} \sum_{t \in \mathcal{W}^{\text{pre}}} Y_{i,t,k},$$

donde $\mathcal{W}^{\text{pre}} = [t_s - 600, t_s)$ y $\mathcal{W}^{\text{post}} = (t_s, t_s + 600]$ son las ventanas de ± 10 minutos respecto al *shock*, expresadas en segundos de reloj de juego. El cambio en el rendimiento del jugador es

$$\Delta_{i,s,k}^{\text{player}} = \bar{Y}_{i,s,k}^{\text{post}} - \bar{Y}_{i,s,k}^{\text{pre}}.$$

Sea $\mathcal{T}_{i,s}$ el conjunto de compañeros de equipo del jugador i en campo en el instante del *shock* s . El cambio colectivo del bloque, evaluado por *leave-one-out* para mantener la independencia formal entre el jugador y su grupo de referencia, es

$$\Delta_{i,s,k}^{\text{team}} = \frac{1}{|\mathcal{T}_{i,s}| - 1} \sum_{j \in \mathcal{T}_{i,s} \setminus \{i\}} (\bar{Y}_{j,s,k}^{\text{post}} - \bar{Y}_{j,s,k}^{\text{pre}}).$$

El delta relativo, sobre el que el CCV estima causalmente, es

$$\Delta_{i,s,k}^{\text{rel}} = \Delta_{i,s,k}^{\text{player}} - \Delta_{i,s,k}^{\text{team}}.$$

Mide la respuesta individual del jugador en el canal k tras el *shock* s , una vez descontado el movimiento colectivo de su bloque.

4.2.2. Diferencias-en-diferencias *within-player*

Sobre el panel de jugador-*shock*-minuto, se especifica el modelo de efectos fijos bidireccionales

$$Y_{i,s,t,k} = \alpha_{i,s,k} + \gamma_{(t-t_s),k} + \tau_k \cdot \mathbf{1}[t > t_s] + \varepsilon_{i,s,t,k},$$

donde $\alpha_{i,s,k}$ son los efectos fijos por par jugador-*shock*, $\gamma_{(t-t_s),k}$ son los efectos fijos por minuto relativo al *shock*, $\mathbf{1}[t > t_s]$ es el indicador del tratamiento (post-*shock*) y τ_k es el efecto medio del tratamiento sobre el canal k . Los errores estándar se calculan *cluster-robust* a nivel jugador (*Cluster Robust Variance type 1*, CRV1), opción robusta para tratamientos de nivel jugador con tasas heterogéneas de *shock* entre individuos. La estimación se contrasta contra el *event-study* de Sun y Abraham —que evita la contaminación entre cohortes— y contra la imputación contrafactual de Borusyak et al. —eficiente bajo paneles desbalanceados. La sensibilidad a violaciones de tendencias paralelas se evalúa con las cotas *HonestDiD* de Rambachan y Roth para tres niveles de relajación de la asunción ($M \in \{0,5,1,2\}$ respecto a la magnitud de las desviaciones pre-tratamiento observadas).

4.2.3. Cuasi-experimento *near-miss*

El segundo brazo causal se apoya en el resultado de Gauriot y Page (2019): condicional a un disparo con xG pre-disparo comparable, el hecho de que el balón entre o no entre se aproxima a un sorteo. La idea del marco es comparar la respuesta del jugador después de un gol marcado con su respuesta después de un *near-miss* técnicamente equivalente, de manera que la variación entre uno y otro caso quede aislada de la calidad técnica del disparo. Sobre el universo de disparos con xG pre-disparo en $[0,15, 0,85]$ del torneo, el conjunto de tratamiento son los goles marcados y el conjunto de control son los *near-misses* de las cinco tipologías ya descritas; los errores estándar se *clusterizan* a nivel disparo, en línea con el tratamiento formal de la interferencia entre unidades de Hudgens y Halloran (2008). La unidad de análisis es el jugador en campo en el momento del disparo y el

outcome es la media del canal k en la ventana $[t_s + 60, t_s + 600]$ segundos posterior al evento.

El estimador principal es un AIPW (*Augmented Inverse Probability Weighting*) doblemente robusto. Su forma cerrada para el canal k es

$$\hat{\tau}_k^{\text{AIPW}} = \mathbb{E} \left[\hat{\mu}_{1,k}(X) - \hat{\mu}_{0,k}(X) + \frac{D(Y - \hat{\mu}_{1,k}(X))}{\hat{e}(X)} - \frac{(1 - D)(Y - \hat{\mu}_{0,k}(X))}{1 - \hat{e}(X)} \right],$$

donde $\hat{\mu}_{d,k}(X)$ es la media condicional del canal k estimada sobre los disparos del brazo $d \in \{0, 1\}$ y $\hat{e}(X)$ es el *propensity score*, ambos aprendidos como modelos *nuisance* con LightGBM y validación cruzada en cinco pliegues estratificada por partido. La construcción sigue el esquema de *Double/Debiased Machine Learning* (DML) de Chernozhukov et al. (2018), que proporciona doble robustez asintótica bajo tres condiciones: correcta especificación de al menos uno de los dos modelos *nuisance*, solapamiento positivo ($0 < \hat{e}(X) < 1$ con margen) y consistencia de los *nuisance* a tasa $n^{-1/4}$. El cumplimiento del solapamiento se verifica empíricamente en la sección de resultados.

Como comprobación complementaria, el efecto medio del tratamiento sobre los tratados (ATT, *Average Treatment effect on the Treated*) se estima también por DML *Partially Linear Regression*, por DR-learner (Kennedy, 2023) y por un RDD (*Regression Discontinuity Design*) local-lineal sobre la discontinuidad en xG , con el *bandwidth* óptimo robusto de Calonico et al. (2014). La sensibilidad del efecto estimado a *confounding* no observado se evalúa con las cotas de Cinelli y Hazlett (2020).

4.2.4. CATE jerárquico bayesiano *multivariate*

El efecto heterogéneo por jugador se condensa en un CATE jerárquico bayesiano *multivariate* sobre los cuatro canales conjuntamente. Sea $\delta_{i,s,k} \equiv \Delta_{i,s,k}^{\text{rel}}$ el delta relativo observado para el jugador i , el *shock* s y el canal $k \in \{1, 2, 3, 4\}$. El modelo es

$$\delta_{i,s,k} \sim \mathcal{N} \left(\mu_{s,k} + \mathbf{x}_{i,s}^\top \boldsymbol{\beta}_k + \eta_{i,s,k} + \eta_{i,k}^{\text{pres}} \cdot z_{i,s}^{\text{elim}}, \sigma_k \right),$$

donde $\mu_{s,k}$ es el efecto poblacional medio por dirección de *shock* y canal; $\mathbf{x}_{i,s}$ es el vector de moduladores continuos del contexto (minuto normalizado, diferencia de marcador post-*shock*, índice de fase, *leverage* y proximidad de eliminación), todos estandarizados; $\eta_{i,s,k}$ es el efecto aleatorio individual por jugador y dirección del *shock*; $\eta_{i,k}^{\text{pres}}$ es el efecto aleatorio individual de respuesta a presión (modulado por $z_{i,s}^{\text{elim}}$, la proximidad de eliminación estandarizada); y σ_k es la desviación estándar residual por canal.

Las correlaciones *cross*-canal del efecto individual se modelan mediante una previa Lewandowski–Kurowicka–Joe (LKJ) sobre la matriz de correlación entre los cuatro canales,

por dirección del *shock*:

$$\boldsymbol{\eta}_{i,s} \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma}_s), \quad \boldsymbol{\Sigma}_s = \mathbf{D}_s \mathbf{R}_s \mathbf{D}_s, \quad \mathbf{R}_s \sim \text{LKJ}(\nu).$$

Los *priors* sobre la media del efecto individual están informados por los *grades* humanos PFF pre-torneo, $g_{i,k}^{\text{PFF}}$, mediante un factor de escala aprendido γ_k :

$$\mathbb{E}[\eta_{i,s,k}] = \gamma_k \cdot g_{i,k}^{\text{PFF}}.$$

Sobre corpus sin *grades* humanos, esta capa de regularización se sustituye por un *prior* débil $\mathbb{E}[\eta_{i,s,k}] \sim \mathcal{N}(0, \sigma_0)$ con σ_0 amplio; la identificación causal no se ve afectada y solo se ensanchan los intervalos de credibilidad individuales por la menor regularización, a costa de cierta pérdida de eficiencia muestral en corpus con tamaño limitado. El uso de los *grades* responde a su disponibilidad en el corpus PFF FC, no a una exigencia estructural del marco.

La parametrización está *non-centered* en todos los efectos aleatorios para evitar la geometría de embudo (Betancourt & Girolami, 2015). El muestreo se realiza con *Hamiltonian Monte Carlo* (HMC) usando el *sampler* No-U-Turn (NUTS) sobre cuatro cadenas independientes con `target_accept_prob` de 0,95 para acomodar la geometría LKJ y la estructura jerárquica.

4.3. Datos

El trabajo utiliza tres fuentes de datos, todas extraídas a parquet con tipos anidados y verificación *round-trip lossless* antes de cualquier análisis. Ningún modelo predictivo del *pipeline* ve un partido del Mundial Qatar 2022 durante el entrenamiento; la única exposición controlada al torneo objetivo es la recalibración por *temperature scaling* de la WP sobre la fase de grupos, descrita más adelante en el protocolo experimental (§4.6).

El corpus objetivo es el Mundial Qatar 2022 con datos PFF FC (PFF FC, 2024), liberado en abierto en septiembre de 2024. Contiene los sesenta y cuatro partidos del torneo con eventos en formato JSON, tracking a 25 Hz sincronizado con los eventos mediante el campo `game_event.start_frame`, presión individual etiquetada, *grades* humanos por evento sobre cuatro dimensiones tácticas y metadatos posicionales.

Los *grades* humanos de PFF FC son valoraciones cualitativas asignadas por analistas internos del proveedor, especializados en *scouting* profesional y formados sobre un protocolo propietario común. Cada acción observada en el partido recibe una puntuación numérica acotada en una escala bipolar centrada en cero —valores positivos representan ejecución por encima de lo esperado para la dificultad del contexto y valores negativos representan ejecución por debajo— a lo largo de cuatro dimensiones independientes: *closing-down*

(presión defensiva sobre el rival con balón), *movement* (calidad del movimiento sin balón en fase ofensiva y defensiva), *position* (lectura del juego y ubicación relativa al bloque y al rival) y decisión con balón (calidad de la acción técnica una vez en posesión). La granularidad por evento —no agregada al partido como otros proveedores comerciales— es lo que hace que el *grade* sea utilizable como *prior* informativo del CATE y como validación externa cualitativa post-hoc. Tras el preprocesado, el corpus cubre quinientos once jugadores con al menos un minuto en campo, doscientos treinta y tres jugadores con minutos suficientes para análisis fiable (≥ 270 min) y ciento setenta y dos goles-*shock* repartidos entre ciento veinte de la fase de grupos y cincuenta y dos de la fase eliminatoria.

El corpus de entrenamiento de la espina dorsal temporal es Wyscout 2017/18 *open dataset*, con 1941 partidos sobre las cinco grandes ligas europeas —*Premier League*, La Liga, *Serie A*, *Bundesliga* y *Ligue 1*— más la Copa del Mundo 2018 y la Eurocopa 2016. Su volumen es suficiente para que el modelo bayesiano de *Win Probability* converja sobre los *bins* de minuto.

El corpus de entrenamiento del Post-Shot xG , del *atomic*-VAEP y de las cabezas defensivas es StatsBomb *open data* filtrado, con ciento treinta y seis partidos sobre Eurocopa 2020, Eurocopa 2024 y *Bundesliga* 23/24, además del propio Mundial Qatar 2022 —que se mantiene como *holdout* sagrado y no se utiliza en ningún entrenamiento. Los partidos StatsBomb incluyen los 360 *freeze-frames*, indispensables para el cálculo del Post-Shot xG a partir de la posición tridimensional final del balón, de la configuración de defensores en cono y de la ubicación del portero.

La única exposición controlada del Mundial Qatar 2022 al *pipeline* de entrenamiento es la recalibración por *temperature scaling* sobre la fase de grupos, que ajusta un único parámetro escalar de temperatura para corregir el desplazamiento de distribución del torneo respecto a las ligas de entrenamiento. La fase eliminatoria queda como *holdout* final donde se evalúan todos los efectos causales reportados en el capítulo de resultados.

4.4. Herramientas y tecnologías

La pila tecnológica está organizada en capas. La capa de datos opera sobre **polars** para procesamiento *lazy* y *streaming* sobre parquet con tipos anidados, **pyarrow** como infraestructura de serialización y **pandas** como interfaz secundaria a librerías de *machine learning* que aún asumen el contrato pandas. La capa de modelado supervisado utiliza CatBoost para *atomic*-VAEP (su tratamiento nativo de variables categóricas simplifica el preprocesado sobre la representación *atomic*-SPADL), LightGBM para Post-Shot xG con búsqueda hiperparamétrica mediante **optuna** (sesenta iteraciones con AUC *out-of-fold*) y calibración isotónica posterior, y **scikit-learn** como envoltorio común para validación cruzada y métricas. La librería **socceraction** en su versión 1.5.3 provee la representación

atomic-SPADL y la familia de modelos VAEF modular utilizada en el canal ofensivo.

La capa de identificación causal en panel utiliza **pyfixest** para los estimadores con efectos fijos —ATE *Two-Way Fixed Effects* (TWFE), Sun y Abraham y Borusyak et al.— con errores estándar *cluster-robust* CRV1, y **doubleml** para el AIPW de doble robustez con *cross-fitting* sobre el corpus de *near-miss*, que es la implementación de referencia de la familia *Double/Debiased Machine Learning* de Chernozhukov et al. (2018).

La capa bayesiana se construye sobre **numpyro** —compilado sobre JAX— para SVI rápido en CPU en los modelos de *Win Probability* y residualización física del canal físico, y para muestreo NUTS HMC en el modelo CATE *multivariate* con aceleración GPU. La parametrización *non-centered* y la geometría LKJ exigen **target_accept_prob** de 0,95 para mantener tasas de aceptación estables sin transiciones divergentes.

La capa de visualización utiliza **mplsoccer** para superficies sobre el campo, **matplotlib** y **seaborn** para estadística descriptiva y **adjustText** para gestión de etiquetas sobre *scatter plots* con *overplotting* denso.

4.5. Métricas de evaluación

Las métricas se agrupan en cuatro familias según la capa que evalúan.

La calibración de los modelos probabilísticos —*Win Probability*, Post-Shot *xG* y las cabezas defensivas de probabilidad de recuperación y de ser atacado— se reporta con cuatro métricas estándar. Sea $\{(\hat{p}_i, y_i)\}_{i=1}^N$ el conjunto de pares (probabilidad predicha, resultado observado) sobre el *holdout*, y sea $\{B_m\}_{m=1}^M$ una partición de los predichos en $M = 10$ *bins* equispaciados. Para cada *bin*, sean $\bar{p}_m = \frac{1}{|B_m|} \sum_{i \in B_m} \hat{p}_i$ la probabilidad media predicha y $\bar{y}_m = \frac{1}{|B_m|} \sum_{i \in B_m} y_i$ la frecuencia empírica observada.

El *Expected Calibration Error* (ECE) es el promedio ponderado de las desviaciones absolutas por *bin*,

$$\text{ECE} = \sum_{m=1}^M \frac{|B_m|}{N} |\bar{p}_m - \bar{y}_m|,$$

y el *Maximum Calibration Error* (MCE) toma la peor desviación,

$$\text{MCE} = \max_m |\bar{p}_m - \bar{y}_m|.$$

La descomposición de Brier de Murphy (1973) separa el *score* en tres componentes:

$$\underbrace{\frac{1}{N} \sum_{i=1}^N (\hat{p}_i - y_i)^2}_{\text{Brier}} = \underbrace{\sum_m \frac{|B_m|}{N} (\bar{p}_m - \bar{y}_m)^2}_{\text{Reliability}} - \underbrace{\sum_m \frac{|B_m|}{N} (\bar{y}_m - \bar{y})^2}_{\text{Resolution}} + \underbrace{\bar{y}(1 - \bar{y})}_{\text{Uncertainty}},$$

donde $\bar{y}$ es la tasa de evento agregada. Un modelo calibrado minimiza *reliability* (predic-

ciones que coinciden con las frecuencias observadas) y maximiza *resolution* (predicciones que separan eventos con tasas distintas); la *uncertainty* es intrínseca al problema y no depende del modelo.

A las cuatro métricas anteriores se añade el área bajo la curva ROC (AUC) en el *holdout* sagrado del Mundial Qatar 2022. La validación cruzada se aplica por partido (*5-fold stratified by match*) para evitar fuga entre eventos del mismo encuentro; la búsqueda hiperparamétrica con **optuna** se realiza sobre la AUC *out-of-fold*.

La identificación causal por DiD se reporta con el ATE estimado por TWFE con *cluster* CRV1 a nivel jugador, los estimadores *event-study* de Sun y Abraham y la imputación contrafactual de Borusyak et al. como verificaciones independientes, las cotas *HonestDiD* de Rambachan y Roth para tres niveles de relajación de tendencias paralelas, y el test *F* de pre-tendencias agregadas (Roth, 2022) como verificación adicional. La identificación causal por AIPW se reporta con el ATT estimado por DoubleMLIRM con *cross-fitting* de cinco pliegues por partido, el ATT por DoubleMLPLR como sanity-check, el DR-*learner* como verificación complementaria y el RDD local-lineal sobre la discontinuidad en xG . La sensibilidad a *confounding* no observado se evalúa con las cotas de Cinelli y Hazlett (2020) sobre el *robustness value* y los *impact parameters*.

La convergencia bayesiana del modelo CATE se diagnostica con dos estadísticos de convergencia y dos condiciones de aceptación del *sampler*. El estadístico potencial-scale-reduction de Gelman-Rubin, $\hat{R} = \sqrt{\hat{V}/W}$ —donde W es la varianza media intra-cadena y $\hat{V}$ es una estimación combinada de la varianza marginal—, debe ser inferior a 1,05 en todos los parámetros muestreados. El *Effective Sample Size* en *bulk*, $ESS_{\text{bulk}} = MN/(1+2\sum_{t=1}^T \hat{\rho}_t)$ —con M cadenas, N muestras por cadena y $\hat{\rho}_t$ la autocorrelación muestral a *lag* t —, debe superar 400 por parámetro para que la posterior se considere suficientemente explorada. Adicionalmente se exige ausencia de transiciones divergentes y ausencia de saturación de profundidad de árbol durante el muestreo. Para cada efecto individual estimado se reportan la media posterior, el intervalo de credibilidad del 95 % y la probabilidad posterior $P(\hat{\beta} > 0 \mid \text{datos})$ —o $P(\hat{\beta} < 0 \mid \text{datos})$ según la dirección esperada del efecto. Los *tiers* de significatividad sobre la posterior se definen en dos umbrales: *Sig* a partir de 0,85 y *Sig-strong* a partir de 0,95.

La correlación entre los canales algorítmicos del CCV y los *grades* humanos PFF se reporta como validación externa cualitativa, agregada por jugador sobre los jugadores con muestra fiable, mediante el coeficiente de correlación de Spearman con su p -valor asociado bajo la hipótesis nula de independencia.

4.6. Protocolo experimental

El protocolo asegura la separación entre datos de entrenamiento y datos de evaluación, controla la inflación de error en comparaciones múltiples y declara explícitamente el rango de potencia estadística que el corpus permite. Los resultados del capítulo siguiente se producen sin excepciones bajo este protocolo.

Separación entrenamiento-evaluación. Ningún modelo predictivo del *pipeline* ve un partido del Mundial Qatar 2022 durante el entrenamiento. La única exposición controlada al torneo objetivo es la recalibración por *temperature scaling* sobre la fase de grupos, con un único parámetro escalar ajustado para corregir el desplazamiento de distribución. La fase eliminatoria, con cincuenta y dos *shocks*, queda como *holdout* final donde se evalúa el efecto causal del *shock* sin haber sido tocada por ningún paso de ajuste.

Comparaciones múltiples. El placebo *within-series* se ejecuta con mil permutaciones sobre los doce contrastes principales (cuatro canales por tres contextos) y se acompaña de corrección Benjamini-Hochberg para controlar la tasa de descubrimiento falsa sobre los ATE poblacionales. Las celdas significativas se reportan tanto con p crudo como con q corregido.

Potencia estadística. El análisis de potencia se realiza ex-ante sobre el panel jugador-*shock*-minuto con simulación Monte Carlo del *Intraclass Correlation Coefficient* (ICC) y del *Minimum Detectable Effect* (MDE) al ochenta por ciento. Para cada canal y contexto se reporta explícitamente el efecto mínimo detectable dado el tamaño de muestra y la dispersión observada en el corpus.

Robustez temporal. La sensibilidad a la ventana de análisis se evalúa sobre cinco horizontes pre/post $-\pm 3, \pm 5, \pm 7, \pm 10$ y ± 15 minutos— y se reportan las desviaciones del efecto estimado respecto al horizonte de referencia. Los resultados se estratifican adicionalmente por fase de grupos y fase eliminatoria para identificar posible heterogeneidad por contexto de torneo.

Identificabilidad por jugador. La tabla *scout-facing* final se restringe a jugadores con al menos dos *shocks* observados —umbral mínimo para que el efecto aleatorio bayesiano por jugador sea identificable— y al menos noventa minutos jugados en el torneo. Un *flag* explícito de `low_sample` marca a los jugadores con menos de ocho *shocks* o menos de doscientos setenta minutos jugados, cuyos intervalos de credibilidad son inevitablemente más anchos y cuyas estimaciones requieren lectura cautelosa.

5 Desarrollo técnico

Este capítulo documenta el desarrollo técnico del *pipeline* del CCV en el orden en que sus capas se ejecutan. Para cada capa se reporta el input que recibe, el método con el que opera —el estado del arte real descrito en el capítulo 3, no una versión ligera— el output que entrega y la validación local que sostiene la elección. La descripción se mantiene a nivel conceptual: los detalles matemáticos de los estimadores ya están formalizados en el capítulo 4 y los resultados cuantitativos se reportan en el capítulo 6.

5.1. Extracción y preprocesado

La capa de extracción recibe los datos brutos del Mundial Qatar 2022 publicados por PFF FC (PFF FC, 2024): sesenta y cuatro ficheros de eventos en formato JSON, sesenta y cuatro ficheros de tracking a 25 Hz en formato *JSON Lines* comprimido, metadatos posicionales y plantillas oficiales. Los datos se serializan a parquet con tipos anidados y verificación *round-trip lossless* antes de cualquier análisis. La elección de parquet sobre JSON está motivada por dos factores prácticos: la lectura columnar acelera por dos órdenes de magnitud las consultas analíticas posteriores, y la compresión Snappy reduce el corpus de tracking de unos 30 GB brutos a 5 GB de cache reutilizable. Los corpus externos de entrenamiento —el *open dataset* Wyscout 2017/18 (Pappalardo et al., 2019) y la liberación de StatsBomb *open data* (StatsBomb, 2024)— se extraen al mismo formato para que el resto del *pipeline* opere con una única abstracción de acceso.

Sobre el cache de parquet se calculan tres normalizaciones que el resto del trabajo asume sin volver a comprobar. La primera es la dirección de ataque por equipo y período, definida como el sentido del campo hacia el que cada equipo dirige su juego en cada parte; permite expresar las coordenadas de tracking en un sistema relativo al ataque del equipo en posesión, condición necesaria para que cualquier métrica basada en distancia al gol sea consistente entre partes y entre partidos. La segunda es la línea temporal de goles válidos, que excluye explícitamente los goles anulados y los tantos de la tanda de penaltis (estos últimos no son *shocks* emocionales en el sentido del marco, dado que se producen fuera del flujo continuo de juego). La tercera son los minutos jugados por jugador y partido, derivados de las alineaciones iniciales más las sustituciones registradas en el *eventing*.

Una corrección técnica adicional resulta relevante para el resto del trabajo: en una parte de los partidos del Mundial, PFF FC entrega el *frame* de tracking rotado 180° respecto al *frame* del *eventing* durante los períodos de prórroga. El preprocesado detecta esta inconsistencia comparando la dirección de ataque registrada en el evento contra la posición del portero en el tracking del mismo *frame* y des-rotar cuando procede. La

detección es automática y silenciosa, y la corrección se aplica en todas las consultas que mezclen coordenadas de tracking con dirección de ataque. El cache resultante constituye la base sobre la que opera el resto del *pipeline*.

5.2. Win Probability y *leverage*

La capa de *backbone* temporal estima la probabilidad de ganar el partido por minuto y deriva de ahí los moduladores continuos del contexto que alimentan al modelo CATE. La especificación replica la propuesta de Robberechts et al. (2021) en `numpyro` sobre JAX: un modelo logit ordinal de tres clases —victoria local, empate, victoria visitante— con interceptos tiempo-variables modulados por una previa de paseo aleatorio sobre los noventa *bins* de minuto, lo que regulariza la suavidad temporal de las probabilidades sin imponer una forma funcional rígida. Las *features* fijadas por minuto son cinco: diferencia de goles, diferencia de tarjetas rojas, diferencia de Elo entre selecciones, indicador de la fase del torneo y la diferencia de tiros en los diez minutos anteriores como proxy de *momentum* ofensivo. El ajuste se realiza por *Stochastic Variational Inference* con guía normal automática, lo que recupera una posterior aproximada en pocos minutos sobre CPU y evita el coste de un muestreo NUTS completo para una capa que solo se usa como modulador del contexto.

El conjunto de entrenamiento agrega 1941 partidos de Wyscout 2017/18 y 136 partidos de StatsBomb *open data* (Eurocopa 2020, Eurocopa 2024 y Bundesliga 2023/24), descartando explícitamente cualquier partido del Mundial Qatar 2022 que aparezca en cualquiera de los dos corpus. La recalibración al torneo objetivo se realiza mediante *temperature scaling* sobre la fase de grupos: se ajusta un único parámetro escalar de temperatura sobre el vector de *logits* predichos para que la curva de calibración sobre la fase de grupos del Mundial coincida con la diagonal. La fase eliminatoria, donde se realizan después los análisis causales, queda intacta como *holdout*.

La cobertura del modelo de Robberechts se restringe a los noventa minutos de regulación, lo que es suficiente para liga pero insuficiente para un torneo eliminatorio con prórroga y tanda de penaltis. El *pipeline* extiende la espina dorsal con dos parches puntuales. La prórroga se modela mediante una tasa de gol con distribución de Poisson estimada sobre las prórrogas históricas disponibles, calibrada para reproducir la frecuencia de gol observada en treinta minutos adicionales. La tanda de penaltis se modela paramétricamente como una secuencia Bernoulli con probabilidad de conversión homogénea por equipo, suficiente para el objetivo de cerrar la curva de WP hasta el desenlace del partido.

De la WP se derivan los dos moduladores continuos que el modelo CATE utiliza como variables de contexto del *shock*. El primero es el *leverage*, definido como la sensibilidad de la probabilidad de ganar a un gol marginal anotado en el instante del análisis, y calculado

como la derivada finita de la WP respecto a un cambio unitario en la diferencia de goles. El segundo es la proximidad de eliminación por equipo y minuto, computada por simulación Monte Carlo del grupo completo durante la fase de grupos (sobre las quinielas restantes condicionadas al estado actual) y directamente por la propia WP, desplazada según la perspectiva del equipo, durante la fase eliminatoria.

La proximidad de eliminación es el modulador que mejor captura el carácter dinámico del *shock* emocional en la fase de grupos, porque incorpora lo que pasa en el otro partido del grupo a través de la simulación Monte Carlo. La figura 5.1 ilustra el fenómeno sobre el caso más extremo del torneo: el último partido del grupo E, España contra Japón. El panel superior reporta la WP del partido para España: sube de un 32 % inicial a más de un 70 % tras el gol de Morata (min 11), cae a un 34 % tras el empate de Doan (min 48) y se hunde al 7 % tras el 2-1 de Tanaka (min 51). El panel inferior reporta la proximidad de eliminación de España derivada por simulación Monte Carlo del grupo dado el estado de los dos partidos simultáneos. Esta es la curva interesante. Pese a que España iba perdiendo 2-1 desde el minuto 51, la proximidad de eliminación se mantenía por debajo del 20 % porque Alemania ganaba a Costa Rica en el partido paralelo. Cuando Vargas marca para Costa Rica en el minuto 60 (CRC 2-1 GER), la proximidad de eliminación de España *salta al 68 %* en el minuto 70 —el pico de la curva—, porque con ese marcador combinado España quedaba fuera por diferencia de goles. La reacción de Alemania en el tramo final (doblete de Havertz y gol de Füllkrug) devuelve la proximidad de eliminación de España al entorno del 10 % en el minuto 85. El intervalo de veinte minutos entre el 60 y el 80 del partido condensa así tres *shocks* emocionales encadenados sobre los jugadores españoles —ninguno generado por una acción suya, todos por lo que pasaba en el otro partido del grupo—, y la WP bayesiana del marco los recoge a través de la proximidad de eliminación sin que ningún gol propio cambie de signo durante esos veinte minutos.

5.3. Post-Shot xG y construcción del corpus de *near-miss*

El cuasi-experimento de *near-miss* requiere un modelo Post-Shot xG calibrado sobre el que evaluar la calidad técnica de cada disparo. El modelo se entrena con LightGBM sobre eventos StatsBomb *open data* fuera del torneo objetivo, lo que proporciona unos 3545 disparos sobre 136 partidos con los *freeze-frames* 360 necesarios para reconstruir la configuración de defensores en el momento del disparo. El conjunto de *features* cubre tres familias: el bloque pre-disparo estándar (posición, distancia y ángulo al gol, parte del cuerpo, técnica, presencia de presión), la posición tridimensional final del balón —incluyendo la altura, que es el ingrediente nuclear del PSxG sobre xG a secas— y la configuración geométrica de defensores y portero derivada del *freeze-frame* 360 (número




Figura 5.1. La cascada de tres *shocks*: España en el grupo E.

de defensores en el cono, distancia al defensor y al compañero más cercanos, posición del portero respecto al *endpoint*). La búsqueda de hiperparámetros se realiza con Optuna sobre 60 iteraciones maximizando la AUC *out-of-fold*, con validación cruzada estratificada por partido para evitar fuga entre eventos del mismo encuentro. Sobre las predicciones *out-of-fold* se ajusta una regresión isotónica que corrige la calibración local; la salida calibrada es la que entra al corpus de *near-miss*.

El corpus se construye sobre cinco tipologías con umbrales pre-registrados que aproximan la cuasi-aleatoriedad del resultado del disparo condicional a su calidad técnica. Cada tipología tiene su propio criterio de detección.

Parada de PSxG alto. Detecta el disparo con expectativa real de gol que el portero desactiva mediante una intervención técnica. La condición de activación es PSxG calibrado mayor o igual que 0,6, o xG pre-disparo mayor o igual que 0,4 que termina en parada ($\text{outcome} \in \{\text{Saved}, \text{Saved To Post}\}$). El PSxG es la métrica primaria porque incorpora la posición final del balón; el xG pre-disparo se usa como respaldo para disparos sin información tridimensional fiable.

Palo o travesaño. *Marker* explícito *Off Target* acompañado de *outcome* de impacto en madera, restringido a disparos con xG pre-disparo en $[0,15, 0,85]$ para evitar capturar remates anecdóticos sin riesgo real de gol ni cabezazos comprometidos desde fuera del área. El disparo sale por azar técnico del marco.

No-gol confirmado por la tecnología de gol. Cruce de la coordenada z del balón sobre el plano de la línea de gol detectado en el tracking PFF FC a 25 Hz, sin que el árbitro conceda gol. El caso paradigmático del corpus es el segundo gol de Japón ante España (rebote de Mitoma sobre línea), que el VAR validó por milímetros tras la activación de la tecnología.

Fuera de juego milimétrico. Offside con margen inferior a 1,5 unidades StatsBomb (aproximadamente 1,37 metros) sobre el 360 *freeze-frame* del disparo; *fallback* a la coordenada x del atacante cuando el *freeze-frame* no está disponible. El umbral excluye los offsides claros (margen mayor que la longitud de un cuerpo humano) y captura solo los que el VAR resolvió por ajuste milimétrico.

Despeje en línea de gol. *Marker* explícito *Saved Off Target* con *outcome* compatible con despeje defensivo dentro del área pequeña. Un defensor extiende la pierna o la cabeza para evitar el gol en una secuencia que de otro modo habría acabado en red.

La tabla 5.1 resume las cinco tipologías con el criterio de detección compactado, el xG *baseline* medio y el conteo final sobre el torneo.

Tabla 5.1. Tipologías del corpus de *near-miss*.

Tipología	Criterio de detección	xG medio	n
Parada PSxG alto	$PSxG \geq 0,6$ o $xG \geq 0,4$ que termina en parada	0,47	42
Palo o travesaño	<i>Marker Off Target</i> con $xG \in [0,15, 0,85]$	0,45	12
No-gol por tecnología	Cruce de coordenada z del balón sobre línea de gol en tracking PFF a 25 Hz	0,07	9
Fuera de juego milimétrico	Offside con margen $< 1,5$ unidades StatsBomb ($\approx 1,37$ m) sobre 360 <i>freeze-frame</i> ; <i>fallback</i> : coordenada x del atacante	—	5
Despeje en línea de gol	<i>Marker</i> explícito <i>Saved Off Target</i>	0,09	2
Total			70

La distribución temporal de los 70 *near-misses* a lo largo del partido es ligeramente sesgada hacia la fase de prórroga: 25 en la primera parte de regulación (P1), 26 en la segunda (P2) y 19 en tiempo extra. El sobre-peso relativo de la prórroga —que solo ocupa el 6 % del tiempo del torneo— es consistente con la mayor intensidad ofensiva característica de las fases eliminatorias abiertas, y refuerza la cobertura del corpus en el régimen de máxima carga emocional. El no-gol confirmado por la tecnología de gol es la tipología más rara del corpus pero está documentada explícitamente en el partido entre Japón y España.

5.4. Identificación de *shocks* y ventanas pre/post

Sobre la línea temporal de goles válidos del preprocesado se etiqueta cada gol como un *shock* emocional con dos perspectivas: GOAL_FOR para los jugadores del equipo que marca y GOAL_AGAINST para los del equipo que recibe. Para cada *shock* se calcula la ventana pre/post de ± 10 minutos respecto al instante t_s del gol, expresados en segundos absolutos de reloj de juego —no en minutos de reloj convencional—, lo que evita errores de alineamiento con la prórroga y con la compensación que el árbitro añade al final de cada parte. La unidad básica que el resto del *pipeline* consume es el par jugador-*shock*: por cada gol válido se generan tantas filas como jugadores había en campo en el instante del gol, lo que da aproximadamente veintidós filas por *shock* y unas tres mil ochocientas filas a nivel jugador para el torneo.

Cada fila lleva una batería de *flags* explícitos que documentan condiciones que comprometen la limpieza de la ventana sin forzar su exclusión: `truncated_pre/post` cuando la ventana queda recortada por el inicio o el fin del partido o por una transición de período, `overlap_flag` cuando otro *shock* del mismo partido cae dentro de los ± 10 minutos del actual, `sub_in_window` cuando el jugador entra o sale del campo dentro de la ventana, y `et_flag` cuando el *shock* ocurre en tiempo extra. La elección de etiquetar sin excluir delega la decisión última en las capas posteriores: el estimador DiD descarta filas con `truncated_post`, el AIPW del cuasi-experimento mantiene incluso ventanas parcialmente solapadas (porque el contraste es entre disparos, no entre minutos), y el CATE bayesiano absorbe la incertidumbre asociada a las filas con `sub_in_window` mediante *Inverse Probability of Censoring Weights* (IPCW) sobre la probabilidad observada de censura.

Sobre el mismo panel jugador-*shock* se calcula la composición *leave-one-out* del bloque colectivo del propio equipo. Para cada par (i, s) , el delta del bloque se evalúa promediando los deltas individuales de los compañeros de equipo en campo en el instante t_s , excluyendo explícitamente al jugador i del cálculo. Si el delta del bloque incluyera al propio jugador, el contraste perdería sentido: el control no sería independiente del tratado, y ningún coeficiente posterior aislaría la respuesta individual del empuje colectivo.

5.5. Los cuatro canales del rendimiento

La cuantificación del rendimiento descompone el comportamiento del jugador en cuatro canales conceptualmente disjuntos: ofensivo, defensivo, *off-ball* y físico. Cada canal se estima con un *building block* de referencia descrito en el capítulo de estado del arte, y produce dos agregaciones que las capas causales consumen: una a nivel jugador-minuto (panel para el DiD *within-player*) y otra a nivel jugador-*shock*-ventana con el delta colectivo *leave-one-out* ya calculado (panel para el AIPW y para el CATE). La tabla 5.2 sintetiza

los cuatro canales.

Tabla 5.2. Resumen de los cuatro canales del rendimiento.

Canal	<i>Building blocks</i>	Entrenamiento	AUC OOF
Ofensivo	<i>atomic</i> -VAEP + <i>un-xPass</i>	456 k acciones + 137 k pases	VAEP 0,83/0,87 + unxP 0,83
Defensivo	VDEP + <i>exPress</i> + atribución <i>frame-nearest</i>	36 k acciones + 88 k presiones	VDEP 0,80/0,83 + exP 0,62
Off-ball	OBSO + C-OBSO	64 partidos a 25 Hz	—
Físico	Bradley + residual bayesiano jerárquico	64 partidos a 25 Hz	—

Cifras redondeadas a dos decimales. Notación VAEP y VDEP: 0,83/0,87 corresponde a las dos cabezas *scores/concedes* del modelo VAEP, y 0,80/0,83 a *recovery/attacked* en VDEP. La auditoría completa de los modelos con tres decimales y comparación contra literatura está en el anexo C.5.

Canal ofensivo. La valoración ofensiva combina dos métricas con interpretación distinta. La primera es *atomic*-VAEP, una variante atómica del marco original de Decroos et al. (2019) en la que cada acción *on-ball* se representa como una unidad indivisible de SPADL (*Soccer Player Action Description Language*) y se valora por su efecto marginal sobre la probabilidad de marcar y la probabilidad de conceder un gol en las próximas N acciones. El modelo se entrena con CatBoost sobre StatsBomb *open data* fuera del Mundial (136 partidos, 456 368 acciones atómicas en total, aproximadamente 3 400 por partido), aprovechando que CatBoost ofrece tratamiento nativo de variables categóricas y simplifica el preprocesado sobre la representación SPADL. La segunda es *un-xPass* (Robberechts et al., 2023), que aporta la dimensión de la decisión: un pase exitoso se valora más cuando se ejecuta desde un estado de juego en el que ese pase concreto era la elección inesperada, no la obvia. La combinación de ambas separa el valor del resultado del valor de la creatividad en la elección.

Canal defensivo. El canal defensivo combina tres *building blocks*. El primero es VDEP estricto (Toda et al., 2022), que mide para cada acción defensiva la probabilidad de recuperación menos un múltiplo de la probabilidad de ser atacado en las próximas N acciones, con el peso entre recuperación y ataque calibrado como el cociente observado entre las dos tasas. El segundo es *exPress*, implementación de Lee et al. (2025) que estima la probabilidad de recuperación del balón en los cinco segundos posteriores a un evento de presión etiquetado por el proveedor, con *features* de *eventing* alineadas al tracking a 25 Hz. El tercero es la atribución al defensor más cercano al balón *frame-level*, esquema consolidado en la literatura sobre tracking: para cada acción ofensiva del rival se reparte el crédito defensivo al defensor más próximo al balón en el *frame* del evento, con signo negativo cuando la acción atacante es exitosa y positivo cuando falla. La suma de los

tres bloques produce un valor defensivo agregado por minuto que captura tanto la acción defensiva explícita como la presencia espacial de presión sin acción registrada.

Canal *off-ball*. La valoración *off-ball* aplica el marco OBSO de Spearman (2018) sobre el tracking PFF a 25 Hz. El factor de control del balón —*Potential Pitch Control Field* (PPCF)— se calcula vectorizado sobre todas las posiciones del campo con la implementación de Spearman 2018 (Eq. 2-4) en numpy con *broadcasting*, idéntica matemáticamente al método original pero compatible con *batches* de *frames* en una sola llamada. El factor de probabilidad de gol estática $S(r)$ utiliza una rejilla de xG basada en la distancia y el ángulo al gol. El factor $T(r, t)$ de tiempo de llegada del balón se aproxima con un núcleo gaussiano respecto a la simulación física exacta del modelo seminal, simplificación documentada y consistente con el alcance del trabajo individual. La extensión contrafactual C-OBSO (Teranishi et al., 2022) se calcula como la diferencia entre el OBSO observado y el OBSO que habría obtenido el jugador si en lugar de moverse se hubiera quedado quieto en su posición previa; la diferencia atribuye al jugador el valor añadido por su movimiento sin balón. La figura 5.2 ilustra el output *frame-level* del PPCF sobre un instante de juego concreto del torneo: el 2-2 que iguala la final Argentina-Francia, con Mbappé disparando desde el área. La gradación cromática refleja el control de espacio del equipo atacante (rojo) frente al defensor (azul) en cada celda del campo; es sobre superficies de este tipo, agregadas a lo largo de los frames de la ventana del *shock*, donde el canal *off-ball* cuantifica el valor del movimiento sin balón.

Canal físico. El canal físico residualiza la respuesta del jugador contra una línea base personal modulada por la curva temporal del minuto, separando la componente decisional —lo que el jugador aprieta dentro de sus posibilidades— de la componente física —lo que el jugador puede. La capa de cálculo *frame-level* aplica un filtro Butterworth *lowpass* de fase cero sobre las velocidades del tracking (frecuencia de corte 1 Hz, siguiendo la convención de Buchheit), un filtro Hampel para *outliers* residuales y un *cap* a 11 m/s preservando la dirección del vector velocidad. Sobre las velocidades suavizadas se calculan tres métricas por jugador, partido y minuto: distancia recorrida, segundos en alta velocidad (HSR, *High-Speed Running*, con umbral de 19,8 km/h en línea con la literatura sobre tracking en torneo) y número de *sprints* (umbral 25 km/h y duración mínima 1 s). El residual respecto a la línea base personal se estima mediante un modelo bayesiano jerárquico ajustado por SVI, con efectos aleatorios por jugador y por partido, y curvas temporales suaves del minuto como *features* comunes; la salida es el *score* físico residualizado por minuto, comparable entre jugadores con ritmos de juego distintos.




Figura 5.2. Superficie PPCF en el 2-2 de la final Argentina-Francia.

5.6. Identificación causal: DiD y *near-miss*

La capa causal estima el efecto del *shock* sobre el delta relativo al bloque mediante las dos estrategias independientes formalizadas en el capítulo 4. El brazo principal es una diferencias-en-diferencias *within-player* sobre el panel jugador-*shock*-minuto. El estimador base es TWFE clásico con efectos fijos por par jugador-*shock* y por minuto relativo al *shock*, ajustado mediante el motor `pyfixest` en su variante de errores *cluster-robust* CRV1 a nivel jugador. La alternativa de *cluster* bidimensional jugador-partido inflaría la varianza con los 64 partidos del torneo sin ganancia estadística que lo justifique. Sobre el mismo panel se ejecutan los estimadores robustos a heterogeneidad de Sun y Abraham (2021) y Borusyak et al. (2024) como verificación cruzada, y las cotas *HonestDiD* de Rambachan y Roth (2023) para tres niveles de relajación de la asunción de tendencias paralelas, junto con el test F de pre-tendencias agregadas (Roth, 2022). Para el tratamiento pulsado-instantáneo del gol, sin tratamientos escalonados y sin unidades *never-treated*, los tres estimadores deberían coincidir en el coeficiente estimado bajo tendencias paralelas y no-anticipación:

la verificación empírica de que efectivamente lo hacen se reporta en el capítulo 6, y la desviación entre ellos se interpreta como cuantificador de la fragilidad del ATE.

El segundo brazo es el cuasi-experimento de *near-miss* sobre el corpus construido en la sección 5.3. La implementación utiliza `doubleml` en su variante *Interactive Regression Model* (DoubleMLIRM), que ajusta los dos modelos *nuisance* —la media condicional del *outcome* para el grupo tratado y el grupo de control, y el *propensity score*— con LightGBM bajo el esquema de *cross-fitting* de Chernozhukov et al. (2018), con cinco pliegues estratificados por partido. Como verificaciones complementarias se estiman el efecto medio del tratamiento sobre los tratados por DML *Partially Linear Regression*, por *DR-learner* (Kennedy, 2023) y por RDD local-lineal sobre la discontinuidad en xG con el *bandwidth* óptimo robusto de Calonico et al. (2014). La sensibilidad a *confounding* no observado se reporta con las cotas de Cinelli y Hazlett (2020) sobre el *robustness value* y los *impact parameters*. La triangulación entre el brazo DiD y el brazo *near-miss* sostiene el resultado: si los dos coeficientes coinciden en signo y magnitud, el efecto se considera identificado; si divergen, esa divergencia acota el *confounding* no controlado por arriba.

5.7. CATE jerárquico bayesiano *multivariate*

La estimación del efecto heterogéneo por jugador captura la varianza individual que el ATE poblacional, indistinguible de cero, no captura. El modelo CATE jerárquico bayesiano *multivariate* formalizado en la sección 4.2 se implementa en `numpyro` sobre JAX y se muestrea por NUTS HMC sobre cuatro cadenas independientes. La parametrización es *non-centered* en todos los efectos aleatorios, siguiendo la recomendación de Betancourt y Girolami (2015) para evitar la geometría de embudo característica de los modelos jerárquicos. La correlación *cross*-canal entre los cuatro canales del rendimiento se modela mediante una previa Lewandowski–Kurowicka–Joe sobre la matriz de Cholesky, con una previa independiente por dirección de *shock* (post-GOAL_AGAINST, post-GOAL_FOR y respuesta a presión modulada por la proximidad de eliminación). Los *priors* sobre la media del efecto individual están informados por los *grades* humanos PFF pre-torneo a través de un factor de escala γ_k por canal aprendido en el ajuste; sobre corpus sin *grades* esta capa de regularización se sustituye por un *prior* débil sin alterar la identificación causal, solo ensanchando los intervalos de credibilidad individuales.

El modelo se sintoniza con `target_accept_prob` de 0,95 para acomodar la curvatura de la previa LKJ y la jerarquía. Antes del ajuste completo se ejecuta un *smoke test* con dos cadenas de doscientos pasos para detectar problemas de identificabilidad o de inicialización; el ajuste de producción utiliza cuatro cadenas, un *warmup* de mil pasos y mil pasos de muestreo. Los criterios de aceptación de convergencia son el estadístico R-hat por debajo de 1,05, el *Effective Sample Size* en *bulk* por encima de 400, la ausencia de transiciones

divergentes y la ausencia de saturación de profundidad de árbol. La posterior resultante alimenta tres outputs principales: el CATE por jugador, dirección de *shock* y canal con sus intervalos de credibilidad del 80 % y 95 %; la probabilidad posterior $P(\beta > 0 \mid \text{datos})$ por jugador y celda, base de los *tiers* de significatividad; y la matriz de correlación *cross*-canal posterior, que permite leer qué canales tienden a moverse juntos por dirección de *shock*.

5.8. Ensamblaje del CCV y tabla *scout-facing*

La capa final ensambla la tabla canónica del CCV con un jugador por fila, combinando la posterior del CATE con los moduladores de contexto, las agregaciones por canal y los metadatos posicionales y de minutos. La tabla cubre los 511 jugadores del torneo con al menos un minuto en campo y mantiene un esquema estable de 299 columnas agrupadas en seis bloques.

El primer bloque, identificación, lleva el nombre del jugador, su selección, sus posiciones registradas por el proveedor y su *bucket* posicional agregado (DEF, MED, ATA o GK).

El segundo, vector resumen por canal, contiene la media posterior del CATE de los cuatro canales en su contexto de mayor señal (ataque post-GA, defensa post-GF, *off-ball* post-GA y físico orientado por dirección dominante).

El tercero, ocho celdas canal-por-contexto, descompone el efecto en sus ocho combinaciones {ofensivo, defensivo, *off-ball*, físico} $\times$ {post-GA, post-GF} con media, desviación, intervalo y probabilidad posterior por celda.

El cuarto, tres índices agregados, condensa la posterior del CATE en tres dimensiones interpretables para el *scouting*. El **Remontador** (post-GA) cuantifica cómo reacciona el jugador en promedio cuando su equipo encaja un gol: promedia el CATE estandarizado de los cuatro canales en la ventana post-GA y captura al jugador que sube su nivel cuando el partido se complica. El **Cerrojo** (post-GF) hace lo simétrico para el gol a favor: promedia los cuatro canales post-GF y captura al jugador que sostiene la solidez tras marcar —ni se relaja ni se deja llevar por el bloque que afloja. El *Pressure Response* es una dimensión continua y no discreta: en lugar de promediar sobre ventanas pre-post, mide la pendiente individual del efecto del *shock* modulada por la proximidad de eliminación estandarizada del partido, y captura al jugador que crece cuando está más cerca de quedar fuera del torneo.

Los dos primeros índices son agregados sobre cuatro canales, y por eso su sensibilidad efectiva depende de que las celdas individuales del canal $\times$ contexto no se cancelen entre sí; el tercero es una sola pendiente y por eso tiene mayor poder estadístico individual, motivo por el que es el índice que produce los cuatro jugadores significativos reportados en el capítulo de resultados mientras los dos primeros quedan infra-identificados sobre el corpus de $N = 172$ *shocks*.

El quinto bloque, *tier strings* de significatividad, recoge etiquetas categóricas por celda y por índice según los umbrales de probabilidad posterior (*Inconclusive*, *Sig*, *Sig-strong*).

El sexto, *rankings* y *flags*, contiene la posición global del jugador en cada índice, su posición dentro de su *bucket* posicional y un *flag low_sample* que marca explícitamente a los jugadores con menos de ocho *shocks* observados o menos de doscientos setenta minutos jugados, cuyos intervalos son inevitablemente más anchos.

Los filtros de identificabilidad se aplican como restricción de las filas elegibles para los *rankings* y para las tablas auxiliares: al menos dos *shocks* observados, umbral mínimo para que el efecto aleatorio bayesiano por jugador sea identificable en el modelo, y al menos noventa minutos jugados, umbral mínimo para que las métricas físicas *per-90* no estén dominadas por ruido. Los jugadores que no cumplen ambos filtros permanecen en la tabla con sus estimaciones, pero quedan marcados con *low_sample* y excluidos por defecto de los *rankings scout-facing* del trabajo final.

Junto a la tabla canónica se generan cuatro tablas auxiliares —*top-10* por posición granular y por *bucket* posicional, *dual-clutch top* y agregación por selección— que condensan los resultados principales para uso de *scouting*. El detalle de cada tabla auxiliar se reporta en el anexo D. Estas tablas, junto con la tabla canónica, constituyen el *output* final del *pipeline* y la base sobre la que se construyen los resultados sustantivos del capítulo siguiente.

6 Resultados

Este capítulo reporta los resultados del CCV sobre el Mundial Qatar 2022 en dos bloques. El primero, validación interna, cubre la calibración de los modelos predictivos del *pipeline* y la robustez del identificador causal. El segundo, resultados sustantivos, descompone el efecto del *shock* a nivel poblacional, lo contrasta con la heterogeneidad individual estimada por el CATE jerárquico bayesiano y aterriza en los jugadores con respuesta significativa por contexto.

6.1. Calibración de los modelos predictivos

La capa predictiva sobre la que descansa el cuasi-experimento de *near-miss* es el modelo Post-Shot *xG*. La figura 6.1 reporta su calibración sobre la fase de grupos del Mundial y sobre el resto de torneos de entrenamiento.




Figura 6.1. Curva de fiabilidad y descomposición de Brier del modelo PSxG.

Las dos curvas se mantienen sobre la diagonal de calibración perfecta en todo el rango, con desviaciones inferiores a un punto porcentual en cada uno de los cuatro *bins* de la regresión isotónica. La AUC *out-of-fold* (OOF) es 0,968 y la AUC sobre el *holdout* del Mundial es 0,976. La AUC alta del modelo respecto al rango clásico de los *xG* pre-disparo (Anzer & Bauer, 2021) es consistente con la ventaja informativa del PSxG, que incorpora *end_y* y *end_z* del disparo y la configuración 360 *freeze-frame* en el instante del lanzamiento; el detalle del análisis y la comparación contra la literatura PSxG están en el anexo C.5. El *Expected Calibration Error* (ECE) sobre el *holdout* es 0,011, y el componente de *reliability* en la descomposición de Brier es 0,0002 —dos órdenes de magnitud por debajo del baseline *xG* pre-disparo de StatsBomb tomado como referencia, con la salvedad de que ambos modelos operan sobre tareas distintas (PSxG post-disparo frente a *xG* pre-disparo).

La componente de *resolution* es 0,0713 sobre el *holdout*, aproximadamente tres veces y media superior al mismo baseline. La combinación de reliability bajo y resolution alto respalda el uso del modelo como ancla técnica del corpus de *near-miss* sin sesgar la asignación entre tratamiento y control.

La capa de *Win Probability* (WP) sigue el mismo protocolo: ajuste sobre Wyscout 2017/18 más StatsBomb fuera del Mundial y recalibración por *temperature scaling* sobre la fase de grupos. La curva de calibración resultante sobre la fase de grupos del Mundial se mantiene próxima a la diagonal de calibración perfecta, con un parámetro de temperatura aprendido ligeramente inferior a la unidad ($T \approx 0,95$), consistente con un desplazamiento de distribución modesto desde la liga europea al torneo de selecciones. La fase eliminatoria queda como *holdout* final donde no se ajusta ningún parámetro.

6.2. Identificación causal: pre-tendencias y sensibilidad

La validación del brazo causal DiD se apoya en tres comprobaciones independientes sobre los coeficientes *within-player*. La primera es el test F de pre-tendencias agregadas (Roth, 2022), que no rechaza la hipótesis nula de paralelismo pre-tratamiento en ninguno de los ocho contrastes canal $\times$ contexto al nivel del cinco por ciento. Los coeficientes pre-shock son indistinguibles de cero en los diez minutos previos al gol en los cuatro canales, lo que es consistente con la asunción de tendencias paralelas necesaria para la identificación del efecto del *shock* —reconociendo que la potencia del test es limitada con el tamaño de muestra disponible, motivo por el que las cotas *HonestDiD* se reportan como verificación complementaria.

La segunda comprobación es la sensibilidad temporal de los coeficientes a la elección de la ventana pre/post. La figura 6.2 reporta el efecto medio estimado sobre horizontes de ± 3 , ± 5 , ± 7 , ± 10 y ± 15 minutos por canal y por dirección del *shock*.

Los coeficientes ofensivo y *off-ball* son estables a través de los cinco horizontes y cercanos a cero en todos ellos. El coeficiente defensivo también es estable, con dispersión adicional en los horizontes más cortos por la menor muestra efectiva. El coeficiente físico es el más sensible al horizonte: en la ventana estándar de ± 10 minutos los efectos son indistinguibles de cero, pero al extender a ± 15 minutos aparecen efectos estadísticamente significativos al cinco por ciento —positivos post-marcar ($+0,053$ desviaciones estándar, $p = 0,0002$) y modestos post-encajar ($+0,032$, $p = 0,047$). El patrón es consistente con una respuesta física diferida que no se manifiesta en la ventana inmediata pero sí en una ventana extendida; la elección de ± 10 minutos como horizonte de referencia es deliberada y se discute en el capítulo siguiente.

La tercera comprobación es la sensibilidad a violaciones de tendencias paralelas mediante




Figura 6.2. Sensibilidad del ATE al horizonte pre/post.

las cotas *HonestDiD* (Rambachan & Roth, 2023), reportadas en el anexo C. Para todos los canales y direcciones, las cotas robustecidas correspondientes a los tres niveles $M \in \{0,5, 1, 2\}$ contienen el cero, lo que indica que los coeficientes nulos del ATE poblacional son estables incluso si la asunción de tendencias paralelas se relaja hasta el doble de la máxima desviación pre-tratamiento observada.

6.3. Efecto poblacional medio del shock

Antes de reportar los coeficientes causales, la tabla 6.1 describe la composición del corpus de *shocks* sobre el que se estiman. El torneo aporta 172 *shocks* de gol únicos repartidos en 64 partidos, con sesgo hacia la fase de grupos por volumen —más partidos por equipo— y hacia los minutos centrales y finales de cada parte. La mitad de los *shocks* comparten ventana con otro *shock* del mismo partido, lo que motiva la decisión de no excluir las ventanas solapadas y de absorber el cruce entre ventanas dentro de los efectos fijos del estimador. Una quinta parte de los *shocks* tiene la ventana pre o post recortada por el inicio o el fin del partido o por una transición de período, condición que el estimador DiD descarta sólo cuando afecta a la ventana post.

El ATE poblacional del *shock* sobre el delta relativo al bloque del propio equipo, estimado por DiD *within-player* con errores estándar *cluster-robust* a nivel jugador, se reporta en la tabla 6.2.

Los ocho coeficientes son indistinguibles de cero al nivel del cinco por ciento, con intervalos de confianza al 95 % que contienen el origen en todas las celdas. La corrección de Benjamini-Hochberg sobre los doce contrastes principales no produce ningún rechazo. El *shock* emocional del gol no mueve, en promedio, el rendimiento del jugador relativo al patrón colectivo de su bloque. El análisis de potencia ex-ante sobre el panel jugador-*shock*-minuto indica que el *Minimum Detectable Effect* (MDE) efectivo al ochenta por ciento de potencia oscila entre 0,0003 desviaciones estándar para el canal *off-ball* y 0,036

Tabla 6.1. Composición del corpus de *shocks* del torneo.

Dimensión	Categoría	<i>n</i>	%
Fase	Grupos	120	69,8
	Eliminatoria	52	30,2
Período	P1 (regulación, 1 ^a parte)	67	39,0
	P2 (regulación, 2 ^a parte)	101	58,7
	P3+P4 (prórroga)	4	2,3
Bucket minuto	1–15	16	9,3
	16–30	17	9,9
	31–45	33	19,2
	46–60	31	18,0
	61–75	31	18,0
	76–90	27	15,7
	91–120	17	9,9
<i>Flags</i> de ventana	Solapamiento con otro <i>shock</i>	86	50,0
	Ventana pre truncada	34	19,8
	Sustitución en ventana	32	18,6
	Ventana post truncada	30	17,4
	Tiempo extra (<i>flag</i>)	4	2,3
	Gol en propia puerta	3	1,7

para el canal físico, lo que sitúa el listón mínimo de detección de los coeficientes nulos en magnitudes muy pequeñas. Con $N = 172$ *shocks* efectivos en el torneo, el promedio poblacional no es el canal por el que se espera que aparezca la señal *clutch*.


6.4. Heterogeneidad individual: el CATE jerárquico

El ATE poblacional indistinguible de cero no implica ausencia de efecto. La estimación del efecto heterogéneo por jugador mediante el CATE jerárquico bayesiano *multivariate* sobre los 511 jugadores con minutos en campo reporta un panorama muy distinto. La figura 6.3 muestra la distribución del CATE individual por canal y dirección del *shock*.

El canal ofensivo presenta la mayor varianza individual entre las celdas: tras marcar, la desviación estándar de los CATE individuales es $\sigma = 0,086$ desviaciones estándar del canal, con efectos individuales que se extienden desde $-0,49$ hasta $+0,37$. El canal físico también presenta varianza relevante, con $\sigma = 0,032$ tras encajar. Los canales defensivo y *off-ball* presentan dispersión menor pero también sustantivamente distinta de cero. El contraste con el ATE poblacional reportado en la sección anterior es directo: el efecto promedio es cero porque los efectos individuales se cancelan al agregarlos, pero los efectos individuales en sí no son cero. La varianza individual es la señal que el promedio esconde, y es la cantidad sobre la que opera la lectura *scout-facing* del trabajo.

Tabla 6.2. ATE del *shock* sobre el delta relativo al bloque, por canal y dirección.

Canal	Contexto	ATE	SE	IC _{95 %} inf.	IC _{95 %} sup.	<i>n</i> shocks
Ofensivo	Tras encajar	+0,0000	0,0003	−0,0005	+0,0005	50
Ofensivo	Tras marcar	−0,0001	0,0004	−0,0008	+0,0007	50
Defensivo	Tras encajar	+0,0013	0,0063	−0,0110	+0,0137	50
Defensivo	Tras marcar	+0,0004	0,0070	−0,0133	+0,0142	50
Off-ball	Tras encajar	+0,0000	0,0001	−0,0002	+0,0002	50
Off-ball	Tras marcar	−0,0000	0,0001	−0,0002	+0,0002	50
Físico	Tras encajar	−0,0094	0,0125	−0,0339	+0,0151	50
Físico	Tras marcar	−0,0007	0,0117	−0,0237	+0,0223	50

**Figura 6.3.** Distribución del CATE individual por canal y contexto.

6.5. Jugadores con respuesta significativa por contexto

Antes de entrar en los nombres concretos, la figura 6.4 ofrece el panorama del torneo sobre los dos índices agregados que el CCV reporta: el Remontador (eje horizontal, respuesta tras encajar) y el Cerrojo (eje vertical, respuesta tras marcar). Cada punto es un jugador del Mundial Qatar 2022 con muestra suficiente, coloreado por su *bucket* posicional. El gráfico permite leer perfiles extremos en cada cuadrante —el doble-clutch arriba a la derecha, el doble-choke abajo a la izquierda— y comprobar visualmente que la mayoría de jugadores se concentra alrededor del origen, en la zona donde el efecto individual está dentro del ruido del estimador.

La tabla 6.3 resume el conteo de jugadores significativos en cada una de las ocho celdas canal-por-contexto y en los tres umbrales del índice *pressure-clutch*. La señal individual se concentra en dos celdas: el canal ofensivo tras marcar (22 jugadores) y la respuesta a la proximidad de eliminación (entre 4 y 10 según el umbral). Las seis celdas restantes son *inconclusive* para todos los jugadores del corpus, lo que encaja con la heterogeneidad reportada en la sección anterior: las celdas con σ del CATE individual más pequeño




Figura 6.4. Panorama del torneo: Remontador frente a Cerrojo.

concentran poca señal por jugador y no producen significatividad posterior individual con $N = 172$ shocks. La discusión operativa de esta asimetría se retoma en el capítulo 7.

Tabla 6.3. Jugadores significativos por celda y por umbral.

Canal	Contexto	PRO	ANTI	Total
Ofensivo	Tras encajar	0	0	0
Ofensivo	Tras marcar	5	17	22
Defensivo	Tras encajar	0	0	0
Defensivo	Tras marcar	0	0	0
Off-ball	Tras encajar	0	0	0
Off-ball	Tras marcar	0	0	0
Físico	Tras encajar	0	0	0
Físico	Tras marcar	0	0	0
Pressure-clutch (umbral 0,80)		6	4	10
Pressure-clutch (umbral 0,85)		3	1	4
Pressure-clutch (umbral 0,95)		1	0	1


Los jugadores con efecto significativo en el contexto de proximidad de eliminación alta —el indicador *pressure-clutch* del CCV— se reportan en la tabla 6.4. La significatividad se define sobre la probabilidad posterior $P(\beta > 0 \mid \text{datos}) \geq 0,85$ para el efecto positivo o $P(\beta > 0 \mid \text{datos}) \leq 0,15$ para el efecto negativo.

La figura 6.5 reporta la ficha *scout-facing* de Mbappé como ilustración del formato por jugador del CCV: doce ejes que cruzan los cuatro canales con los tres contextos del *shock*, expresados como percentil dentro de su posición sobre el corpus del torneo. La lectura

Tabla 6.4. Jugadores con efecto *pressure-clutch* significativo.

Jugador	Selección	Media post.	IC _{80%} inf.	IC _{80%} sup.	$P(\beta > 0)$
Kylian Mbappé	Francia	+0,110	+0,029	+0,193	0,97
Marcus Rashford	Inglaterra	+0,050	-0,003	+0,110	0,89
Bukayo Saka	Inglaterra	+0,051	-0,009	+0,116	0,86
Mohammed Muntari	Qatar	-0,055	-0,120	+0,004	0,12

del radar requiere una precisión metodológica relevante: el percentil que muestra cada eje no es una medida de significatividad del efecto causal sobre ese jugador, sino su *ranking* relativo dentro de su *bucket* posicional. Un percentil alto indica que el jugador está entre los más altos de su posición en esa celda, pero la magnitud absoluta del efecto puede seguir siendo indistinguible de cero si la probabilidad posterior por jugador no cruza el umbral de significatividad. Las dos lecturas —percentil posicional y probabilidad posterior por jugador— son complementarias y se reportan conjuntamente en la tabla canónica del CCV; el anexo A reproduce las fichas equivalentes para Messi, Hakimi y Brozović.

**Figura 6.5.** Ficha *scout-facing* de Kylian Mbappé.

Los tres jugadores con efecto positivo significativo están liderados por Kylian Mbappé, con un coeficiente de +0,110 desviaciones estándar y probabilidad posterior 0,97. La identificación es consistente con la observación cualitativa de su irrupción en el cierre de la final Argentina-Francia, donde concentró cuatro de los seis goles del partido en una ventana corta de máxima presión por eliminación. Marcus Rashford y Bukayo Saka, ambos por Inglaterra, completan el grupo positivo con magnitudes equivalentes en torno a +0,050 desviaciones estándar y probabilidades posteriores respectivamente 0,89 y 0,86. El caso negativo significativo corresponde a Mohammed Muntari, cuyo coeficiente cae por debajo

de cero con probabilidad posterior $P(\beta < 0) = 0,88$ —es decir, $P(\beta > 0) = 0,12$ en la tabla 6.4.

A nivel canal-específico, la celda ofensivo-tras-marcar concentra la mayor cantidad de efectos individuales significativos: veintidós jugadores presentan respuesta significativa al *shock* de marcar sobre su producción ofensiva inmediata, cinco con coeficiente positivo y diecisiete con coeficiente negativo. La figura 6.6 reporta el panorama del torneo sobre las dos celdas ofensivas: ataque tras marcar (eje horizontal) y ataque tras encajar (eje vertical), con un punto por jugador.




Figura 6.6. Panorama del torneo: ataque tras marcar frente a ataque tras encajar.

Los cinco con efecto positivo son Eric Maxim Choupo-Moting, Dušan Vlahović, Raheem Sterling, Harry Kane y Cristiano Ronaldo, en orden decreciente de probabilidad posterior. La narrativa de cada caso —celebración seguida de involucración mayor en jugadas posteriores, búsqueda activa de un segundo gol— es consistente con los grades humanos PFF para esos mismos jugadores en los partidos del torneo. Los diecisiete con efecto negativo incluyen al propio Mbappé, cuyo CATE ofensivo-tras-marcar es significativamente negativo ($P(\beta > 0) = 0,004$): tras anotar, su producción ofensiva inmediata cae respecto al patrón colectivo de Francia. La combinación es coherente: Mbappé responde fuertemente bajo presión de eliminación pero relaja su intensidad ofensiva en la ventana inmediata después de marcar, dejando momentáneamente que el bloque recupere el control del partido.

En los agregados de la tabla *scout-facing* —el Remontador post-encajar y el Cerrojo post-marcar— no se identifican jugadores significativos a nivel poblacional. El motivo es matemático: cada agregado es la suma de cuatro celdas canal-por-contexto cuyos efectos

individuales tienden a no estar correlacionados en signo, lo que reduce la señal individual al promediarlos. La respuesta condicional al contexto de eliminación inminente, en cambio, es identificable porque opera sobre un eje único de modulación.

6.6. Validación cualitativa contra los *grades* humanos PFF

Como verificación externa cualitativa, se calcula la correlación de Spearman entre las puntuaciones del CCV por canal y por índice agregado y el *grade* humano PFF agregado por jugador, sobre los 166 jugadores con al menos 270 minutos jugados y muestra fiable. La cifra es modesta en términos absolutos —un tercio del corpus total del torneo— y conviene tenerlo presente al interpretar los coeficientes: la validación direccional opera sobre una muestra acotada, no sobre una población amplia de *labels* humanos. La tabla 6.5 reporta los coeficientes.

Tabla 6.5. Correlación de Spearman entre CCV y *grade* humano PFF.

Métrica CCV	ρ Spearman	p	Significativa
Canal ofensivo (<i>ccv_atk</i>)	+0,017	0,83	—
Canal defensivo (<i>ccv_def</i>)	−0,071	0,37	—
Canal <i>off-ball</i> (<i>ccv_off</i>)	+0,211	0,006	1 %
Canal físico (<i>ccv_phys</i>)	+0,090	0,25	—
Índice Remontador (<i>chasing</i>)	+0,177	0,022	5 %
Índice Cerrojo (<i>protecting</i>)	+0,005	0,94	—
Índice <i>Pressure Response</i>	−0,122	0,12	—

El patrón es modesto y heterogéneo. El canal *off-ball* es el único que correlaciona significativamente al uno por ciento con el *grade* humano agregado ($\rho = +0,211$); el índice Remontador lo hace al cinco por ciento ($\rho = +0,177$). Los demás coeficientes no se distinguen de cero con la muestra disponible. El *grade* humano PFF disponible es un valor único agregado por jugador y partido que sintetiza el rendimiento global, no una descomposición por canal o por contexto de *shock*. Los canales del CCV, en cambio, son métricas *event-level* agregadas por minuto y residualizadas contra el bloque colectivo del propio equipo en cada *shock*. Las dos medidas cubren propiedades parcialmente solapadas pero no idénticas, y eso explica que la correlación varíe tanto entre canales. La validación externa no es contundente: valida direccionalmente que el canal *off-ball* y el agregado Remontador recogen propiedades reconocibles por evaluadores humanos expertos, sin pretender que los CATE y los *grades* midan lo mismo.

7 Discusión

Este capítulo discute los resultados del capítulo 6 desde tres ángulos sucesivos: qué demuestran los datos del Mundial Qatar 2022 sobre la pregunta de investigación; qué no demuestran y por qué la lectura debe ser cautelosa en varios frentes; y dónde el CCV funciona como herramienta de medida y dónde su poder es insuficiente. El capítulo cierra con las implicaciones operativas para *scouting*, mercado de fichajes, preparación de partidos de fase eliminatoria y gestión de cambios desde el banquillo.

7.1. Qué sostienen los resultados

El primer hallazgo es que la señal *clutch* a nivel individual es identificable causalmente sobre un corpus relativamente pequeño —ciento setenta y dos *shocks* de gol en un torneo eliminatorio— cuando la identificación se hace condicional al contexto adecuado. La dimensión sobre la que la identificación es estable es la respuesta a la proximidad de eliminación: tres jugadores muestran efecto positivo significativo a probabilidad posterior $\geq 0,85$ —Mbappé, Rashford y Saka— y uno muestra efecto negativo significativo —Muntari—, todos consistentes con la narrativa cualitativa de sus partidos en el torneo. La magnitud del efecto de Mbappé (+0,110 desviaciones estándar del canal con probabilidad posterior 0,97) sobre la final Argentina-Francia se alinea con la observación pública de su irrupción concentrada en los últimos veinte minutos de regulación y la prórroga. El marco recupera ese caso como una propiedad medida del jugador, no como una intuición *post hoc* del observador.

El segundo hallazgo invierte la lectura habitual del ATE. La distribución del CATE individual reportada en §6.4 — $\sigma = 0,086$ en ofensivo tras marcar, rango $[-0,49, +0,37]$ desviaciones estándar— es sustantivamente distinta de cero, mientras que las ocho celdas canal-por-contexto del ATE poblacional son indistinguibles de cero. La consecuencia operativa para el scouting es directa: un ATE nulo no implica ausencia de efecto, implica que los efectos individuales de signo opuesto se cancelan al agregarlos. La firma corresponde a la concepción clásica del *clutch* en deporte (Otten, 2009): el mismo *shock* produce respuestas opuestas en jugadores distintos, y el promedio cancela esa variabilidad.

El tercer hallazgo es la coherencia parcial con la valoración humana experta. De los cinco canales-índice contrastados contra el *grade* PFF agregado, dos resultan significativos (*off-ball* $\rho = +0,211$ y Remontador $\rho = +0,177$, detalle en §6.6) y tres no. La lectura es que el marco recoge una dimensión reconocible por evaluadores humanos en parte de los canales, pero CATE y *grades* no son medidas intercambiables: el *grade* agrega el partido en un único valor por jugador, mientras el CATE residualiza por minuto y por *shock*.

El cuarto hallazgo es metodológico. La identificación causal a nivel individual se sostiene sobre la composición de las cinco capas formalizadas en el capítulo 4: el contraste temporal pre/post sobre el mismo jugador, los efectos fijos jugador-*shock* en el DiD, la residualización *leave-one-out* contra el bloque del propio equipo, el cuasi-experimento *near-miss* y el AIPW con doble robustez. El cuasi-experimento de *near-miss* aporta una segunda vía identificativa sobre el corpus de 70 disparos pre-registrados; con ese tamaño, el brazo opera a nivel agregado y no permite verificación cruzada por jugador, restricción declarada en §7.2. El test F de pre-tendencias agregadas (Roth, 2022) no rechaza la hipótesis de paralelismo en ninguno de los ocho contrastes, y las cotas *HonestDiD* (Rambachan & Roth, 2023) para los tres niveles de relajación contienen el cero en todos los casos. Los coeficientes nulos del ATE no parecen, por tanto, un artefacto de violación de identificación, sino una propiedad del corpus.

7.2. Qué no sostienen los resultados

El primer punto de cautela es la interpretación del ATE poblacional. Que los ocho coeficientes canal-por-contexto sean indistinguibles de cero al cinco por ciento no es prueba de que el *shock* no mueva al jugador promedio. Es prueba de que, con el tamaño de muestra disponible —en torno a cincuenta *shocks* efectivos por celda tras filtros de ventana y disponibilidad—, el efecto promedio no es detectable por encima del nivel de ruido. El análisis de potencia ex-ante sitúa el *Minimum Detectable Effect* (MDE) al ochenta por ciento de potencia entre 0,0003 desviaciones estándar para el canal *off-ball* y 0,036 para el canal físico. Si el verdadero efecto poblacional cae por debajo de esos umbrales, el marco no lo recupera con $N = 172$ *shocks*; lo que se puede decir es que el efecto promedio no es lo bastante grande para discernirse sobre este corpus, no que sea cero. Por eso el capítulo previo reporta el ATE con su IC y declara la indistinguibilidad de cero en lugar de afirmar la nulidad.

El segundo punto es la generalización fuera del torneo. La aplicación del CCV se restringe al Mundial Qatar 2022 porque es el único corpus público que combina los tres ingredientes estructurales que el marco exige simultáneamente: *eventing* sincronizado con tracking continuo *full-pitch* de los 22 jugadores a 25 Hz y cobertura completa de fase eliminatoria. PFF añade además *grades* humanos por evento, que el marco aprovecha como *prior* informativo y validación externa pero no exige como condición de aplicabilidad. Las propiedades individuales identificadas para los cuatro jugadores con efecto significativo *pressure-clutch* corresponden a su comportamiento en este torneo concreto; no son una predicción de su comportamiento en otros contextos competitivos ni una validación de su perfil “*clutch*” como rasgo estable. Replicar el marco sobre la Eurocopa 2024, sobre los partidos de eliminatoria de la *Champions League* o sobre cualquier otro torneo abierto

futuro permitiría empezar a hablar de la estabilidad temporal de la propiedad; el corpus actual solo permite observar su existencia en un único torneo.

El tercer punto es la limitación del brazo del cuasi-experimento de *near-miss*. El corpus de 70 *near-misses* sobre las cinco tipologías es reducido y deja al AIPW sin potencia para detectar efectos individuales. La triangulación entre DiD y *near-miss* se reporta a nivel agregado y coincide cualitativamente en signo, pero a nivel individual el contraste entre los dos brazos no es testable con este corpus. Por eso el trabajo toma el DiD *within-player* como brazo principal y reporta el AIPW como verificación complementaria; la triangulación rigurosa por jugador queda como línea futura cuando los corpus disponibles permitan ejecutarla.

El cuarto punto es que el CCV mide una forma específica de *clutch*, no *clutch* en sentido amplio. Los tres contextos del marco —post-gol a favor, post-gol en contra y proximidad de eliminación alta— identifican momentos donde la carga emocional y la presión competitiva cruzan un umbral observable a nivel de evento o de contexto. Hay situaciones de presión competitiva genuina que quedan fuera del marco por no encajar en ese umbral: un mediocampista que protege un empate en el minuto noventa de un partido de fase de grupos con ambos equipos ya clasificados está bajo presión, pero sin un *shock* emocional discreto ni proximidad de eliminación inminente que el marco pueda etiquetar como tratamiento. La identificación causal a nivel individual exige momentos con umbral identificable; el contraste de un jugador en momentos *clutch* difusos sin ese umbral queda fuera del alcance del trabajo. La frontera no es metodológica sino de muestra: con un corpus mayor y un catálogo más amplio de tipologías de *trigger* —por ejemplo, segmentos de partido condicionados al estado del marcador combinado con la trascendencia clasificatoria, o ventanas en torno a sustituciones tácticas—, el alcance operativo del marco podría extenderse a momentos hoy fuera del umbral identificable.

El quinto punto matiza el alcance de la correlación con los *grades* humanos PFF. Los dos coeficientes significativos (reportados arriba en §7.1) se calculan sobre 166 jugadores con muestra fiable, un tercio del corpus total. La interpretación adecuada no es que los CATE midan “lo mismo” que el ojo humano experto: el CATE estima el efecto del *shock* residualizado contra el bloque, y el *grade* agrega el rendimiento completo del partido. El alineamiento es direccional, no de magnitud.

7.3. Dónde funciona y dónde no funciona el CCV

El CCV resulta útil como herramienta de medida en tres frentes sobre el corpus disponible. El primero es la dimensión *pressure-clutch*: la modulación continua del CATE por la proximidad de eliminación produce efectos individuales estables y medibles con la muestra disponible. Cuatro jugadores cruzan el umbral de significatividad a probabilidad posterior $\geq$

0,85, todos con narrativa cualitativa coherente con sus partidos en el torneo. El segundo es la celda canal-específica ataque-tras-marcar: veintidós jugadores presentan efecto significativo, repartidos entre cinco con respuesta positiva y diecisiete con respuesta negativa. La presencia de Mbappé en ambos grupos —positivo en *pressure-clutch* y negativo en ataque-tras-marcar— es informativa: el marco distingue, sobre el mismo jugador, propiedades contextualmente diferenciadas que un único agregado escondería. El tercer frente es la lectura *scout-facing*: la tabla canónica del CCV, con un jugador por fila y los tres índices condensados, es operativa para uso de *scouting* sobre el corpus.

El marco no funciona, sobre este corpus, en los agregados Remontador y Cerrojo. La razón es estructural y no metodológica. Cada agregado es la suma ponderada de cuatro celdas canal-por-contexto cuyas posteriores no están correlacionadas en signo entre canales, de modo que el efecto agregado se suaviza al promediarlas. Con $N = 172$ *shocks* repartidos entre 120 de fase de grupos y 52 de eliminatoria, el agregado por dirección queda infra-identificado incluso para los jugadores con la respuesta individual más fuerte. La identificación condicional al contexto de eliminación inminente, en cambio, opera sobre un eje único de modulación y permite que el efecto individual emerja sobre el ruido.

El marco tampoco funciona, sobre este corpus, en el canal físico a la ventana de referencia ± 10 minutos. El análisis de sensibilidad reportado en §6.2 sí detecta efectos significativos al ampliar a ± 15 minutos, lo que sugiere una respuesta física diferida fuera de la ventana inmediata posterior al *shock*. La ventana ± 10 se mantiene como referencia por su correspondencia con la duración del *shock* emocional en la psicología del deporte; el canal físico a horizonte ampliado queda como línea futura.

7.4. Implicaciones operativas

Scouting y mercado de fichajes. El CCV produce una tabla *scout-facing* con un jugador por fila y tres índices —Remontador, Cerrojo y *Pressure Response*— acompañados de la media posterior, el intervalo de credibilidad y la probabilidad posterior por jugador, además de los *rankings* dentro de su posición granular y dentro de su *bucket* posicional. Esa estructura permite separar, para un fichaje concreto, la prima clutch atribuible al jugador de la atribuible al bloque del equipo en el que ha rendido históricamente. Un director deportivo que valora a un jugador con reputación *clutch* adquirida en un equipo grande puede inspeccionar el delta relativo al bloque LOO sobre el corpus disponible y comprobar si la propiedad sobrevive al control por el patrón colectivo de su equipo en cada *shock*. La interpretación recomendada es cautelosa: el marco no produce una decisión, produce una métrica informada por evidencia causal que se combina con el conocimiento táctico y económico del propio departamento.

Preparación de partidos de fase eliminatoria. La identificación de *pressure-clutch* a nivel individual sobre el contexto de eliminación inminente tiene implicaciones directas para la preparación de partidos KO. Los jugadores con efecto positivo significativo bajo proximidad de eliminación alta son candidatos naturales a recibir más minutos en los partidos de mayor presión, mientras que los jugadores con efecto negativo significativo son candidatos a ser rotados antes de los tramos críticos del calendario. La decisión sigue siendo del cuerpo técnico; el marco proporciona una métrica con identificación causal sobre la respuesta histórica del jugador a este contexto concreto, no una predicción individual sobre el siguiente partido.

Gestión de cambios y rotación. La celda ataque-tras-marcador muestra que diecisiete jugadores caen significativamente en su producción ofensiva inmediata después de anotar, incluido Mbappé. Algunos perfiles ofensivos aflojan en los minutos posteriores al gol, justo cuando el equipo es más vulnerable a un contragolpe; para esos perfiles concretos puede tener sentido rotar o ajustar tácticamente la ventana post-marcador. Los cinco jugadores con respuesta positiva en la misma celda —Choupo-Moting, Vlahović, Sterling, Kane y Cristiano Ronaldo— presentan el patrón opuesto: mantener su peso ofensivo después del gol empuja la búsqueda del segundo tanto.

Lectura general y cuándo no usar el marco. El CCV es una herramienta de medida bajo supuestos identificables, no un oráculo sobre la propiedad *clutch* de un jugador. Produce estimaciones con intervalo de credibilidad y probabilidad posterior; la decisión final siempre suma información que el marco no observa —táctica, psicológica, médica, contextual del partido siguiente. Hay tres usos en los que el marco no debe sustituir al juicio experto: la valoración de jugadores con muestra *low_sample* (marcados explícitamente en la tabla), la proyección de la propiedad a contextos competitivos no observados y la atribución *post hoc* del resultado de un partido a un *shock* concreto. En esos usos el marco aporta información, pero no concluye; el reporte sigue siendo la media posterior con su intervalo, no un valor puntual.

8 Conclusiones

8.1. Conclusiones generales

Este trabajo se planteó la pregunta de si la respuesta del jugador a los *shocks* emocionales del partido —el gol a favor, el gol en contra y la proximidad de eliminación— puede estimarse causalmente a nivel individual, residualizada contra el patrón colectivo de su propio equipo, sobre los cuatro canales del rendimiento. La memoria propone el marco CCV (Causal Clutch Value), lo aplica al Mundial Qatar 2022 con datos PFF FC y produce una tabla *scout-facing* por jugador, canal y contexto con cuantificación de la incertidumbre individual. El trabajo cierra con cuatro conclusiones sustantivas.

La primera es que la identificación causal del efecto del *shock* a nivel individual es viable sobre un corpus relativamente pequeño —172 *shocks* de gol en 64 partidos— cuando descansa sobre la composición de cinco capas: contraste temporal pre/post del mismo jugador, efectos fijos jugador-*shock* en el DiD, residualización *leave-one-out* contra el bloque, cuasi-experimento *near-miss* como triangulación independiente y AIPW con *cross-fitting* para confounders observables. La composición es necesaria por construcción (§4.2): omitir cualquiera de las cinco capas reintroduce un confusor estructural distinto.

La segunda es que la pregunta de investigación tiene respuesta empírica diferenciada según la dimensión. En proximidad de eliminación, cuatro jugadores cruzan el umbral de significatividad (Mbappé, Rashford y Saka con efecto positivo; Muntari con efecto negativo); en ofensivo-tras-marcador, veintidós jugadores presentan efecto significativo (detalle de signos en §6.4). Las seis celdas canal-por-contexto restantes son indistinguibles de cero con el tamaño de muestra disponible. El ATE poblacional indistinguible de cero coexiste con esa heterogeneidad porque los efectos individuales de signos opuestos se cancelan al agregarlos: ATE nulo no implica ausencia de efecto.

La tercera es que el marco recoge una propiedad parcialmente alineada con la valoración humana experta: dos de cinco canales-índice correlacionan positivamente con el *grade* PFF agregado (*off-ball* $\rho = +0,211$ y Remontador $\rho = +0,177$). La asimetría entre ambas medidas —el *grade* agrega el partido en un único valor por jugador, el CATE residualiza por minuto y por *shock*— explica que el alineamiento sea direccional sin ser intercambiable.

La cuarta es metodológica. El CCV integra nueve bloques que la literatura aplicada había desarrollado por separado —WP bayesiana, *atomic*-VAEP, *un-xPass*, VDEP estricto, *exPress*, atribución al defensor más cercano *frame-level*, OBSO, C-OBSO y protocolo físico Bradley— sobre una identificación causal dual con cinco capas conjuntas. El marco es portable a cualquier corpus que reúna la combinación estructural de *eventing* sincronizado con tracking a alta frecuencia y cobertura completa de fase eliminatoria; los *grades* humanos

por evento son un ingrediente deseable —aportan *prior* informativo al CATE y validación externa cualitativa— pero no son condición de aplicabilidad, y el marco corre sobre corpus sin ellos sustituyendo el *prior* informativo por uno débil sin afectar la identificación causal. La aplicación al Mundial Qatar 2022 funciona como banco de pruebas técnico, no como objetivo en sí. La contribución sustantiva del trabajo no son los nombres concretos de los jugadores identificados —que son una propiedad del torneo, no del jugador como rasgo estable— sino la composición metodológica que permite estimarlos causalmente y reportarlos con cuantificación de la incertidumbre.

8.2. Limitaciones

El trabajo está sujeto a tres limitaciones declaradas en detalle en el anexo B y discutidas en el capítulo 7.

La primera es la cobertura limitada al Mundial Qatar 2022, único corpus público que combina los tres ingredientes estructurales que el marco exige simultáneamente (*eventing*, tracking sincronizado a alta frecuencia y cobertura completa de fase eliminatoria). Replicar sobre Eurocopa, eliminatorias de *Champions League* o el siguiente Mundial requiere futuras liberaciones abiertas con esa misma estructura mínima; los *grades* humanos por evento son deseables pero no condición necesaria.

La segunda es la implementación propia de los *building blocks* distintos a *atomic-VAEP*. El canal ofensivo utiliza la librería oficial `socceraction 1.5.3`, mantenida por los autores originales y validada en la literatura aplicada. Los demás bloques —PPCF, C-OBSO, VDEP estricto, *exPress* y la atribución al defensor más cercano *frame-level*— son reimplementaciones propias derivadas de la lectura directa de los *papers* originales, validadas mediante reproducción de cifras agregadas publicadas y comparación con *outputs* de proveedores comerciales cuando existe solapamiento. El nivel de validación es razonable para un trabajo individual de máster, pero no equivale al grado de madurez ni de adopción comunitaria de una librería oficial mantenida.

La tercera es la potencia limitada del brazo *near-miss* para identificación causal a nivel individual. El corpus efectivo de *near-misses* sobre las cinco tipologías pre-registradas restringe la triangulación con el DiD al nivel agregado, dejando la verificación cruzada rigurosa por jugador como una línea futura.

8.3. Líneas futuras

El trabajo abre cinco líneas concretas de extensión.

Más data sobre el mismo formato. Aplicar el *pipeline* sobre un volumen mayor de partidos con estructura equivalente al Mundial Qatar 2022 permitiría obtener estimaciones más representativas de la naturaleza de cada jugador. Con más *shocks* por jugador la posterior del CATE se estrecha y las celdas hoy inconclusivas pueden empezar a separar señal del ruido. La condición técnica estructural es la disponibilidad de *eventing* sincronizado con tracking a alta frecuencia; los *grades* humanos son un ingrediente deseable cuando están disponibles —enriquecen el *prior* del CATE y habilitan validación externa— pero no son necesarios para recalibrar el *pipeline* sin cambios estructurales.

Otras competiciones. La replicación sobre escenarios distintos al Mundial añade dimensiones nuevas a la lectura *clutch*, cada una con su propio perfil de presión emocional.

- **Mundial frente al resto.** El Mundial concentra la máxima carga emocional posible —representación nacional, eliminación a partido único, frecuencia cuatrienal— y constituye la cota superior contra la que cualquier otra competición se contrasta. La existencia o no de un efecto *clutch* bajo estas condiciones extremas es la pregunta nuclear, y el banco de pruebas del presente trabajo.
- **Ligas domésticas.** El formato de liga abre ejes que el Mundial no contiene: local contra visitante, tramo final del calendario con la clasificación a Europa en juego, descenso inminente o pelea por el título; rival evaluado por su nivel (*low*, *mid* o *top*). Cada eje es una dimensión continua o categórica adicional sobre la que medir la respuesta individual al *shock*.
- **Champions League.** El formato de eliminatoria a doble partido aporta una asimetría que el Mundial no tiene: la ida no es eliminación inmediata, la vuelta sí. La misma maquinaria aplicada sobre el contraste ida-vuelta dentro de la misma eliminatoria, sobre el contraste local-visitante o sobre las rondas sucesivas (octavos, cuartos, semifinales, final) permite medir la modulación del *clutch* por el grado de eliminación inminente y por la condición de campo.

Ampliación del corpus de *near-miss*. El trabajo prioriza el DiD *within-player* como brazo principal porque el corpus efectivo de *near-misses* sobre 64 partidos es de solo 70 disparos. Un corpus multitorneo con *near-misses* acumulados sobre varios cientos de partidos permitiría ejecutar la triangulación DiD $\leftrightarrow$ AIPW rigurosamente por jugador, y no solo a nivel agregado.

Ampliación del catálogo de *shocks*. Los tres contextos cubiertos por el presente trabajo —post-gol a favor, post-gol en contra y proximidad de eliminación alta— son los momentos donde la carga emocional cruza un umbral observable. Quedan fuera situaciones

de presión genuina sin *trigger* discreto: defender un empate en el cierre de un partido con ambos equipos ya clasificados, o jugar tras la entrada de un recambio táctico que cambia el equilibrio del bloque. Con un corpus mayor sería posible extender el catálogo a tipologías condicionadas al estado del marcador combinado con la trascendencia clasificatoria del partido, ventanas en torno a sustituciones tácticas o fases de superioridad o inferioridad numérica.

Portabilidad a la valoración de equipos. El delta colectivo del bloque —lo que el *leave-one-out* sustrae de la respuesta individual— también es informativo por sí mismo: cuantifica cómo reacciona el bloque al *shock* antes de individualizar la respuesta. Agregar el CCV a nivel de equipo con la misma maquinaria causal aplicada al delta colectivo produciría una métrica de identidad reactiva —“*clutch* del bloque”— que complementa la lectura por jugador del trabajo actual.

Referencias bibliográficas

- Anzer, G., & Bauer, P. (2021). A Goal Scoring Probability Model for Shots Based on Synchronized Positional and Event Data in Football (Soccer). *Frontiers in Sports and Active Living*, 3, 624475. <https://doi.org/10.3389/fspor.2021.624475>
- Betancourt, M., & Girolami, M. (2015). Hamiltonian Monte Carlo for Hierarchical Models [arXiv:1312.0906]. En S. K. Upadhyay, U. Singh, D. K. Dey & A. Loganathan (Eds.), *Current Trends in Bayesian Methodology with Applications* (pp. 79-101). Chapman; Hall/CRC.
- Borusyak, K., Jaravel, X., & Spiess, J. (2024). Revisiting event-study designs: Robust and efficient estimation. *Review of Economic Studies*, 91(6), 3253-3285. <https://doi.org/10.1093/restud/rdae007>
- Bradley, P. S. (2024). Setting the Benchmark Part 1: The Contextualised Physical Demands of Positional Roles in the FIFA World Cup Qatar 2022. *Biology of Sport*, 41(1), 261-270. <https://doi.org/10.5114/biolsport.2024.131090>
- Bransen, L., Robberechts, P., Van Haaren, J., & Davis, J. (2019). Choke or Shine? Quantifying soccer players' abilities to perform under mental pressure. *Proceedings of the 13th MIT Sloan Sports Analytics Conference*.
- Calonico, S., Cattaneo, M. D., & Titiunik, R. (2014). Robust Nonparametric Confidence Intervals for Regression-Discontinuity Designs. *Econometrica*, 82(6), 2295-2326. <https://doi.org/10.3982/ECTA11757>
- Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1), C1-C68. <https://doi.org/10.1111/ectj.12097>
- Cinelli, C., & Hazlett, C. (2020). Making sense of sensitivity: extending omitted variable bias. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 82(1), 39-67. <https://doi.org/10.1111/rssb.12348>
- Decroos, T., Bransen, L., Van Haaren, J., & Davis, J. (2019). Actions speak louder than goals: Valuing player actions in soccer. *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 1851-1861. <https://doi.org/10.1145/3292500.3330758>
- Fernández, J., Bornn, L., & Cervone, D. (2021). A framework for the fine-grained evaluation of the instantaneous expected value of soccer possessions. *Machine Learning*, 110(6), 1389-1427. <https://doi.org/10.1007/s10994-021-05989-6>
- Gauriot, R., & Page, L. (2019). Fooled by performance randomness: Overrewarding luck. *Review of Economics and Statistics*, 101(4), 658-666. https://doi.org/10.1162/rest_a_00783

- Hahn, P. R., Murray, J. S., & Carvalho, C. M. (2020). Bayesian Regression Tree Models for Causal Inference: Regularization, Confounding, and Heterogeneous Effects (with Discussion). *Bayesian Analysis*, 15(3), 965-1056. <https://doi.org/10.1214/19-BA1195>
- Hudgens, M. G., & Halloran, M. E. (2008). Toward Causal Inference With Interference. *Journal of the American Statistical Association*, 103(482), 832-842. <https://doi.org/10.1198/016214508000000292>
- Iapteff, L., Le Coz, S., Rioland, M., Houde, T., Carling, C., & Imbach, F. (2025). Toward interpretable expected goals modeling using Bayesian mixed models. *Frontiers in Sports and Active Living*, 7, 1504362. <https://doi.org/10.3389/fspor.2025.1504362>
- Kennedy, E. H. (2023). Towards optimal doubly robust estimation of heterogeneous causal effects. *Electronic Journal of Statistics*, 17(2), 3008-3049. <https://doi.org/10.1214/23-EJS2157>
- Klemp, M., Wunderlich, F., & Memmert, D. (2021). In-play forecasting in football using event and positional data. *Scientific Reports*, 11, 24139. <https://doi.org/10.1038/s41598-021-03157-3>
- Konefał, M., Szmigiel, B., Bochenek, B., Morgans, R., & Żmijewski, P. (2024). Match running performance preceding scoring and conceding a goal in men's professional soccer. *Scientific Reports*, 14, 12885. <https://doi.org/10.1038/s41598-024-63785-3>
- Lee, M., Jo, G., Hong, M., Bauer, P., & Ko, S.-K. (2025). exPress: Contextual Valuation of Individual Players Within Pressing Situations in Soccer [Consultado el 27 de mayo de 2026]. *Proceedings of the MIT Sloan Sports Analytics Conference*. <https://www.sloansportsconference.com/research-papers/contextual-valuation-of-individual-players-within-pressing-situations-in-football>
- Morgans, R., Radnor, J., Oliver, J., Scholten, J., Zmijewski, P., Kavanagh, R., Ryan, B., Haslam, C., King, M., & Oliveira, R. (2025). Can different scores in first and second halves influence running and explosive-based measures? *Biology of Sport*, 42(2), 169-175. <https://doi.org/10.5114/biol sport.2025.144296>
- Murphy, A. H. (1973). A New Vector Partition of the Probability Score. *Journal of Applied Meteorology*, 12(4), 595-600. [https://doi.org/10.1175/1520-0450\(1973\)012<0595:ANVPOT>2.0.CO;2](https://doi.org/10.1175/1520-0450(1973)012<0595:ANVPOT>2.0.CO;2)
- Otten, M. (2009). Choking vs. Clutch Performance: A Study of Sport Performance under Pressure. *Journal of Sport and Exercise Psychology*, 31(5), 583-601. <https://doi.org/10.1123/jsep.31.5.583>
- Pappalardo, L., Cintia, P., Rossi, A., Massucco, E., Ferragina, P., Pedreschi, D., & Giannotti, F. (2019). A public data set of spatio-temporal match events in soccer competitions. *Scientific Data*, 6, 236. <https://doi.org/10.1038/s41597-019-0247-7>

- PFF FC. (2024). PFF FC release: 2022 World Cup data [Consultado el 24 de mayo de 2026].
- Rambachan, A., & Roth, J. (2023). A more credible approach to parallel trends. *Review of Economic Studies*, 90(5), 2555-2591. <https://doi.org/10.1093/restud/rdad018>
- Robborechts, P., Van Haaren, J., & Davis, J. (2021). A Bayesian Approach to In-Game Win Probability in Soccer. *Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD '21)*, 3512-3521. <https://doi.org/10.1145/3447548.3467194>
- Robborechts, P., Van Roy, M., & Davis, J. (2023). un-xPass: Measuring Soccer Player's Creativity. *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD '23)*. <https://doi.org/10.1145/3580305.3599924>
- Roth, J. (2022). Pretest with Caution: Event-Study Estimates after Testing for Parallel Trends. *American Economic Review: Insights*, 4(3), 305-322. <https://doi.org/10.1257/aeri.20210236>
- Spearman, W. (2018). Beyond Expected Goals. *Proceedings of the 12th MIT Sloan Sports Analytics Conference*.
- StatsBomb. (2024). StatsBomb Open Data [Consultado el 24 de mayo de 2026].
- Sun, L., & Abraham, S. (2021). Estimating dynamic treatment effects in event studies with heterogeneous treatment effects. *Journal of Econometrics*, 225(2), 175-199. <https://doi.org/10.1016/j.jeconom.2020.09.006>
- Teranishi, M., Tsutsui, K., Takeda, K., & Fujii, K. (2022). Evaluation of creating scoring opportunities for teammates in soccer via trajectory prediction. *Machine Learning and Data Mining for Sports Analytics. ECML-PKDD 2022 Workshop*, 13800. https://doi.org/10.1007/978-3-031-27527-2_5
- Toda, K., Teranishi, M., Kushiro, K., & Fujii, K. (2022). Evaluation of soccer team defense based on prediction models of ball recovery and being attacked: A pilot study. *PLOS ONE*, 17(1), e0263051. <https://doi.org/10.1371/journal.pone.0263051>

A Visualizaciones complementarias

Este anexo recoge las visualizaciones complementarias del cuerpo principal: las fichas *scout-facing* por jugador para tres casos paradigmáticos del torneo distintos al de Mbappé reportado en la figura 6.5, los *scatter* de la selección de Francia sobre las dos combinaciones de índices del CCV, la figura *event-study* de la verificación de robustez en diferencias-en-diferencias y las cotas *HonestDiD* de sensibilidad a violaciones de paralelismo.

A.1. Fichas *scout-facing* adicionales

Las figuras A.1, A.2 y A.3 reportan la ficha equivalente para tres jugadores con perfiles contextuales distintos al de Mbappé. La lectura aplica el mismo criterio que la figura 6.5 del cuerpo principal: el percentil que muestra cada eje es la posición relativa del jugador dentro de su *bucket* posicional sobre el corpus del torneo, no una medida de significatividad estadística del efecto causal sobre el jugador. La probabilidad posterior por jugador y celda, base de los *tiers* de significatividad, se reporta por separado en la tabla canónica del CCV.




Figura A.1. Ficha *scout-facing* de Lionel Messi.

A.2. Vista por equipo: Francia

Las figuras A.4 y A.5 reproducen los dos *scatter* del cuerpo principal restringidos a los jugadores de la selección campeona, con la nube del resto del torneo como contexto de




Figura A.2. Ficha *scout-facing* de Achraf Hakimi.

fondo. La lectura por equipo permite identificar la posición relativa de cada jugador del bloque francés sobre el panorama agregado.

A.3. Verificación causal por *event-study*

La figura A.6 reporta los coeficientes del estudio de eventos por minuto relativo al *shock*, estimados mediante el estimador robusto a heterogeneidad de Sun y Abraham (2021). La ausencia de tendencia sistemática en los minutos pre-*shock* es consistente con el test F de pre-tendencias agregadas (Roth, 2022) reportado en el capítulo 6.

A.4. Sensibilidad *HonestDiD* a violaciones de paralelismo

La figura A.7 reporta las cotas de sensibilidad de Rambachan y Roth (2023) sobre el ATE poblacional para tres niveles de relajación de la asunción de tendencias paralelas. Los intervalos contienen el cero en todos los casos, lo que es consistente con la indistinguibilidad de cero reportada para el ATE en el capítulo 6.




Figura A.3. Ficha scout-facing de Marcelo Brozović.




Figura A.4. Vista por equipo (Francia): Remontador frente a Cerrojo.




Figura A.5. Vista por equipo (Francia): ataque tras marcar frente a ataque tras encajar.




Figura A.6. *Event-study* por minuto relativo al *shock*.




Figura A.7. Cotas *HonestDiD* sobre el ATE poblacional.

B Limitaciones metodológicas en detalle

Este anexo amplía las cautelas declaradas en la sección 7.2 del capítulo 7 con tres familias de limitaciones que el lector debe considerar para no sobre-interpretar los resultados.

B.1. Implementación propia frente a librerías de referencia

El canal ofensivo utiliza *atomic*-VAEP a través de *socceraction* 1.5.3 (Decroos et al., 2019), la implementación oficial mantenida por los autores originales. Los demás *building blocks* —PPCF de Spearman (2018), C-OBSO de Teranishi et al. (2022), VDEP estricto de Toda et al. (2022), *exPress* de Lee et al. (2025) y la atribución *frame-level* al defensor más cercano— son reimplementaciones propias derivadas de la lectura directa de los *papers* originales. La validación es triple: (i) reproducción de las cifras agregadas reportadas en los *papers*; (ii) comparación con *outputs* comerciales (PFF FC, StatsBomb) en corpus solapados; (iii) consistencia interna entre canales sobre los mismos jugadores. El nivel es razonable para un trabajo de máster, pero las reimplementaciones no tienen la madurez ni la adopción comunitaria de una librería oficial; cualquier hallazgo numérico que dependa de manera crítica de la implementación exacta debería contrastarse con una segunda implementación cuando esté disponible.

B.2. Cobertura limitada al Mundial Qatar 2022

El CCV se aplica al Mundial Qatar 2022 por ser el único corpus público que combina simultáneamente *eventing* sincronizado, tracking continuo *full-pitch* de los 22 jugadores a 25 Hz, cobertura completa de fase eliminatoria y rosters oficiales. PFF añade además *grades* humanos por evento, que el marco utiliza como *prior* informativo y validación externa pero no como condición estructural. Las propiedades individuales identificadas corresponden a este torneo concreto, no son una predicción para otros contextos. Los 172 *shocks* sobre 64 partidos sitúan el tamaño de muestra efectivo en el extremo bajo de lo que la identificación causal a nivel individual admite.

B.3. Sub-corpus de *near-miss* reducido

El cuasi-experimento de *near-miss* depende de 70 disparos efectivos sobre las cinco tipologías pre-registradas. Es suficiente para triangular con el DiD a nivel agregado, pero no para identificar efectos individuales con poder estadístico. La estrategia conservadora es priorizar el DiD como brazo principal; la triangulación rigurosa por jugador queda como línea futura sobre corpus mayores.

B.4. Qué *no* captura el CCV

Por construcción, el marco deja fuera cinco fenómenos relevantes para la lectura causal completa.

Picos concentrados de uno o dos minutos. El CATE modela respuesta sostenida en la ventana ± 10 min. Un jugador con una jugada decisiva concentrada en uno o dos minutos cuyo delta promedio en la ventana es modesto queda subestimado. El caso paradigmático es Mbappé en los minutos 80–82 de la final, con el doblete en 97 segundos: el marco lo etiqueta como *pressure-clutch* significativo, pero la magnitud del CATE infraponderada respecto a la concentración del pico.

Tanda de penaltis. Excluida del *scope* causal por ser un deporte distinto. No entra en `n_shocks` ni en CATE; los intervalos y los *rankings* cubren regulación más prórroga.

Tarjetas, sustituciones y lesiones como *shock*. Solo goles y *near-misses* cuentan como tratamiento. Las tarjetas, sustituciones y lesiones entran como *flags* de exclusión (`sub_in_window`, `truncated_pre/post`) pero no como *shock* propio.

Comportamiento colectivo del rival. El bloque *leave-one-out* es del propio equipo del jugador. La reacción del rival queda absorbida en el delta del bloque propio y no se atribuye por separado.

Granularidad temporal de un minuto. Los moduladores continuos del contexto (minuto normalizado, leverage, proximidad de eliminación, etc.) se evalúan a nivel de *shock*, no a nivel de segundo. Cambios sub-minuto del contexto no entran en el estimador.

C Validaciones empíricas adicionales

Este anexo recoge los diagnósticos de robustez que complementan los reportados en el capítulo 6. Cada validación se ejecuta sobre el panel jugador-*shock*-minuto del Mundial Qatar 2022 y se reporta en su tabla correspondiente.

C.1. Test de placebo

El test de placebo recoloca el *shock* en instantes aleatorios del partido distintos del gol real y vuelve a estimar el ATE por DiD *within-player* sobre cada celda canal-por-contexto. Si la identificación causal es válida, el ATE real debe quedar fuera del intervalo de confianza al 95 % de la distribución placebo (H_0 : no hay efecto del *shock*). La tabla C.1 reporta el resultado.

Tabla C.1. Test de placebo sobre las ocho celdas canal-por-contexto.

Canal	Contexto	ATE real	Placebo media	Placebo SD	p emp.	ATE $\in$ IC ₉₅
Ofensivo	Tras marcar	+0,00055	+0,00004	0,00136	0,71	Sí
Ofensivo	Tras encajar	+0,00000	-0,00001	0,00027	0,98	Sí
Defensivo	Tras marcar	-0,00023	+0,00011	0,00711	0,96	Sí
Defensivo	Tras encajar	+0,00108	-0,00014	0,00635	0,86	Sí
Off-ball	Tras marcar	-0,00002	-0,00000	0,00012	0,91	Sí
Off-ball	Tras encajar	+0,00001	+0,00000	0,00011	0,96	Sí
Físico	Tras marcar	-0,00178	+0,00106	0,01179	0,82	Sí
Físico	Tras encajar	-0,01055	-0,00011	0,01266	0,39	Sí

El ATE real cae dentro del IC 95 % de la distribución placebo en las ocho celdas, y el p empírico a dos colas es superior a 0,39 en todas. La corrección de Benjamini-Hochberg sobre las ocho hipótesis no produce ningún rechazo. La lectura es consistente con el ATE poblacional indistinguible de cero reportado en el capítulo 6: el test de placebo no rechaza la nulidad porque el ATE real es ya cercano al ruido de la distribución placebo, no porque la identificación esté mal especificada.

C.2. Análisis de potencia ex-ante

El análisis de potencia ex-ante calcula el *Minimum Detectable Effect* (MDE) al 80 % de potencia que admite el panel por celda, ajustado por la correlación intra-cluster del estimador *cluster-robust* a nivel jugador (*design effect*). La tabla C.2 reporta el MDE efectivo por canal y contexto.

Tabla C.2. Potencia ex-ante por celda canal-por-contexto.

Canal	Contexto	n efectivo	ICC	MDE 80 %	ATE/MDE
Ofensivo	Tras marcar	469	0,057	0,00347	0,16
Ofensivo	Tras encajar	476	0,000	0,00074	0,00
Defensivo	Tras marcar	492	0,000	0,01904	0,01
Defensivo	Tras encajar	433	0,205	0,01833	0,06
Off-ball	Tras marcar	472	0,048	0,00031	0,05
Off-ball	Tras encajar	446	0,140	0,00030	0,02
Físico	Tras marcar	492	0,000	0,03281	0,05
Físico	Tras encajar	460	0,074	0,03579	0,29

El MDE efectivo oscila entre 0,00030 desviaciones estándar del canal *off-ball* y 0,03579 del canal físico tras encajar. El cociente ATE/MDE es inferior a 0,3 en todas las celdas, lo que sitúa los efectos observados muy por debajo del listón mínimo de detección al 80 % de potencia con el tamaño de muestra disponible. La potencia del panel para detectar efectos promedio en este corpus es baja, y la lectura individual del CATE bayesiano recupera la señal que el ATE poblacional no captura.

C.3. Estratificación por fase del torneo

La estratificación por fase del torneo separa el ATE por grupos (120 *shocks*) y por fase eliminatoria (52 *shocks*) y verifica si la diferencia entre ambos contextos es sustantiva. La tabla C.3 reporta los coeficientes y los p -valores por celda y por fase.

Tabla C.3. ATE estratificado por fase del torneo.

Canal	Contexto	Fase de grupos			Fase eliminatoria		
		ATE	SE	p	ATE	SE	p
Ofensivo	Tras marcar	+0,00055	0,00149	0,71	+0,00056	0,00204	0,78
Ofensivo	Tras encajar	+0,00002	0,00030	0,94	-0,00005	0,00054	0,93
Defensivo	Tras marcar	-0,00086	0,00734	0,91	+0,00125	0,01487	0,93
Defensivo	Tras encajar	+0,00109	0,00785	0,89	+0,00106	0,00995	0,92
Off-ball	Tras marcar	+0,00001	0,00015	0,96	-0,00007	0,00014	0,65
Off-ball	Tras encajar	-0,00000	0,00012	0,99	+0,00003	0,00020	0,88
Físico	Tras marcar	-0,00279	0,01440	0,85	+0,00056	0,02000	0,98
Físico	Tras encajar	-0,01456	0,01518	0,34	-0,00121	0,02237	0,96

Ningún coeficiente cruza el cinco por ciento de significatividad en ninguna fase. La diferencia entre fase de grupos y fase eliminatoria no es sustantiva en ninguna celda, lo que es consistente con la identificación causal a nivel individual: la heterogeneidad detectable del CCV reside en el efecto individual del jugador condicional al contexto (proximidad de eliminación, dirección del *shock*) y no en el promedio poblacional por fase del torneo.

C.4. Diagnósticos de calibración del PSxG

La tabla C.4 reporta los diagnósticos completos de calibración del modelo Post-Shot xG sobre los dos conjuntos relevantes: el *out-of-fold* del entrenamiento StatsBomb (3545 disparos, 136 partidos fuera del Mundial) y el *holdout* del Mundial Qatar 2022 (1494 disparos, 64 partidos). Se incluyen las tres descomposiciones que la sección 4.5 del capítulo 4 formaliza: AUC, ECE binado, MCE, Brier y su descomposición de Murphy en *reliability*, *resolution* y *uncertainty*.

Tabla C.4. Diagnósticos de calibración del modelo PSxG.

Conjunto	Modelo	AUC	Brier	ECE	MCE	Rel.	Res.
<i>OOF</i>	PSxG calibrado	0,968	0,0415	0,009	0,67	0,00009	0,054
<i>OOF</i>	PSxG <i>raw</i>	0,971	0,0415	0,013	0,12	0,00031	0,055
<i>OOF</i>	xG StatsBomb	0,826	0,0744	0,009	0,15	0,00022	0,020
<i>WC22</i>	PSxG calibrado	0,976	0,0372	0,011	0,13	0,00018	0,071
<i>WC22</i>	PSxG <i>raw</i>	0,979	0,0374	0,012	0,17	0,00063	0,072
<i>WC22</i>	xG StatsBomb	0,844	0,0829	0,017	0,18	0,00035	0,030

La AUC del PSxG calibrado sobre el *holdout* del Mundial es 0,976, unos trece puntos por encima del xG baseline. La descomposición de Brier sitúa la *reliability* dos órdenes de magnitud por debajo de la *resolution* sobre *WC22*: la desviación entre probabilidad predicha y frecuencia empírica por *bin* es despreciable frente a la capacidad discriminativa agregada. La MCE sube de 0,12 a 0,67 tras calibrar, pero esa métrica captura la peor desviación local sobre *bins* pequeños y se interpreta junto al ECE, que en cambio mejora de 0,013 a 0,009. La transferencia al *holdout* del Mundial preserva la calibración (ECE = 0,011, *reliability* = 0,0002), las cifras que el capítulo 6 reporta como ancla técnica del modelo sobre el corpus objetivo.

C.5. Auditoría de modelos predictivos del pipeline

La tabla C.5 consolida la auditoría de los modelos predictivos del *pipeline*: AUC fuera de muestra (*out-of-fold*, OOF), AUC sobre el conjunto de entrenamiento cuando aplica como medida de sobreajuste, y la referencia bibliográfica con el rango de AUC reportado por el paper original. El *script* de auditoría que reproduce esta tabla a partir de los *caches* del repositorio está disponible en `src/audit_models.py`.

Tres lecturas son relevantes para el lector. Primero, la AUC del PSxG (0,968 OOF, 0,976 *holdout*) está por encima del rango reportado en la literatura (0,84–0,88). La diferencia se explica por dos características del modelo: el uso de las coordenadas tridimensionales finales del balón (end_y , end_z) como *features* legítimas del PSxG —que diferencian conceptualmente

Tabla C.5. Auditoría de los modelos predictivos del *pipeline* frente a la literatura.

Modelo	AUC OOF	AUC train	Δ overfit	AUC lit.	Referencia
PSxG (cal)	0,968	—	—	0,84–0,88	Anzer & Bauer 2021
VAEP <i>scores</i>	0,834	0,907	0,073	0,86–0,91	Decroos et al. 2019
VAEP <i>concedes</i>	0,873	0,930	0,062	0,85–0,88	Decroos et al. 2019
un-xPass	0,831	—	—	0,82–0,84	Robberechts et al. 2023
VDEP recuperación	0,795	—	—	F1 > 0,48	Toda et al. 2022
VDEP atacado	0,831	—	—	F1 > 0,48	Toda et al. 2022
<i>exPress</i>	0,617	—	—	0,607 (XGB)	Lee et al. 2025

PSxG de *xG* pre-disparo— y la incorporación de la configuración de defensores y portero del 360 *freeze-frame* de StatsBomb, no disponible en la mayoría de implementaciones de la literatura. La feature `end_x`, que sí captura determinísticamente el resultado del disparo (si supera la línea de gol), queda explícitamente excluida del entrenamiento; lo mismo ocurre con `ff_keeper_dist_end`. La AUC *holdout* sin penaltis ($n = 1430$) es 0,9751, prácticamente idéntica a la AUC *holdout* con penaltis (0,9755), lo que confirma que el modelo no depende de las celdas fáciles del penalti para discriminar.

Segundo, los modelos de *atomic*-VAEP presentan un Δ *overfit* de 0,073 (*scores*) y 0,062 (*concedes*) entre la AUC sobre entrenamiento y la AUC *out-of-fold*. El *overfit* es moderado y la lectura operativa se hace sobre la AUC OOF, sobre la que actúa además la calibración isotónica ajustada sobre las predicciones *out-of-fold*.

Tercero, los demás modelos quedan dentro del rango de la literatura de referencia. *exPress* reproduce con precisión la AUC reportada por Lee et al. (2025) con LightGBM (implementación equivalente a XGBoost del paper original); un-xPass y VAEP *concedes* coinciden con sus rangos publicados, y los modelos VDEP de recuperación y atacado superan F1 > 0,48 con AUC OOF de 0,795 y 0,831 respectivamente.

D Tablas *scout-facing* complementarias

Este anexo reúne las tablas *scout-facing* que extienden la tabla canónica del CCV. La sección D.1 reporta los veintidós jugadores con respuesta significativa en la celda ofensivo-tras-marcar, la celda canal-por-contexto con más señal individual del torneo. Las secciones D.2, D.3 y D.4 reportan las tablas auxiliares —*dual-clutch top*, *top pressure-clutch* del *bucket* atacante y agregación por selección— que junto con la tabla canónica constituyen el *output scout-facing* final del *pipeline*.

D.1. Veintidós jugadores significativos en ofensivo-tras-marcar

La tabla D.1 reporta los veintidós jugadores con probabilidad posterior $|P(\beta)| \geq 0,85$ en la celda ofensivo-tras-marcar, ordenados por la media posterior del CATE. Cinco jugadores presentan efecto positivo (suben su producción ofensiva tras marcar) y diecisiete presentan efecto negativo (se relajan tras marcar y bajan su producción ofensiva inmediata). Los intervalos de credibilidad reportados son al 80 %, coherentes con el resto de tablas *scout-facing* del trabajo.

La asimetría entre signos (cinco positivos, diecisiete negativos) es lo que explica el ATE poblacional indistinguible de cero en esta misma celda: los efectos individuales no se cancelan exactamente pero sí lo bastante como para que el promedio no cruce significatividad sobre $N = 172$ *shocks*. La lectura sustantiva es que post-marcar tiende a ser un momento de relajación ofensiva inmediata para la mayoría de jugadores con muestra suficiente —incluido Mbappé, paradójicamente—, con un pequeño grupo de delanteros (Vlahović, Choupo-Moting, Sterling, Ronaldo, Kane) que mantiene o sube su producción.

D.2. *Dual-clutch top*: Remontador y Cerrojo simultáneamente

La tabla D.2 reporta los jugadores con la mayor puntuación combinada Remontador + Cerrojo sobre el corpus del torneo. La intersección de las dos dimensiones identifica al jugador con respuesta agregada positiva tanto tras encajar como tras marcar, sin desplazarse a ninguno de los dos extremos. Ninguno de los jugadores listados cruza el umbral de significatividad bayesiana en el agregado dual —propiedad esperable dada la

Tabla D.1. Veintidós jugadores con respuesta significativa en ofensivo-tras-marcar.

Jugador	Sel	Pos	CATE	IC80 lo	IC80 hi	$P(\beta > 0)$
Dušan Vlahović	SRB	CF	+0,37	+0,07	+0,70	0,95
Eric Maxim Choupo-Moting	CMR	CF	+0,35	+0,08	+0,65	0,96
Raheem Sterling	ENG	LW	+0,30	+0,04	+0,59	0,93
Cristiano Ronaldo	POR	CF	+0,24	−0,02	+0,50	0,88
Harry Kane	ENG	CF	+0,23	+0,01	+0,47	0,91
Joao Felix	POR	LW	−0,20	−0,46	+0,04	0,14
Mehdi Taremi	IRN	CF	−0,25	−0,53	+0,02	0,12
Jordan Henderson	ENG	CM	−0,26	−0,51	−0,01	0,09
Roozbeh Cheshmi	IRN	MCB	−0,26	−0,56	+0,02	0,12
Vinícius Junior	BRA	LW	−0,27	−0,52	−0,02	0,08
Cody Gakpo	NED	AM	−0,28	−0,53	−0,04	0,06
Saleh Al-Shehri	KSA	CF	−0,29	−0,60	−0,01	0,09
Mohammed Kudus	GHA	CM	−0,30	−0,59	−0,03	0,08
Bukayo Saka	ENG	RW	−0,31	−0,56	−0,06	0,05
Andrej Kramarić	CRO	CF	−0,32	−0,59	−0,06	0,06
Wout Weghorst	NED	CF	−0,32	−0,62	−0,04	0,07
Aleksandar Mitrović	SRB	CF	−0,40	−0,69	−0,12	0,03
Kai Havertz	GER	CF	−0,43	−0,76	−0,14	0,02
Kylian Mbappé	FRA	LW	−0,45	−0,68	−0,22	0,00
Gonçalo Ramos	POR	CF	−0,46	−0,76	−0,18	0,01
Marcus Rashford	ENG	LW	−0,49	−0,81	−0,19	0,01
Vincent Aboubakar	CMR	CF	−0,49	−0,82	−0,19	0,01

infra-identificación de los índices agregados sobre $N = 172$ *shocks* discutida en el capítulo 6—, pero el ordenamiento muestra perfiles consistentes con la intuición del *scouting* (laterales y mediocentros con presencia omnipresente en ambas fases del juego).

Tabla D.2. *Dual-clutch top*: ranking combinado Remontador + Cerrojo.

Jugador	Sel	Pos	Remontador	Cerrojo	Dual	P_{dual}
Achraf Hakimi	MAR	RB	+0,029	+0,016	+0,045	0,42
Marcelo Brozović	CRO	CM	+0,016	+0,017	+0,033	0,38
Hakim Ziyech	MAR	RW	+0,009	+0,022	+0,031	0,36
Christian Pulisic	USA	LW	+0,024	+0,006	+0,030	0,35
Bartosz Bereszynski	POL	LB	+0,012	+0,018	+0,030	0,35
Min Jae Kim	KOR	RCB	+0,012	+0,017	+0,029	0,36
Jordan Pickford	ENG	GK	+0,001	+0,025	+0,027	0,35
Alisson	BRA	GK	+0,003	+0,023	+0,026	0,34

D.3. *Top pressure-clutch* del *bucket* atacante

La tabla D.3 reporta los ocho atacantes con mayor índice *Pressure Response* en el *bucket* ATA. El ranking está dominado por Mbappé, el único atacante del torneo que cruza el umbral fuerte de probabilidad posterior ($\geq 0,95$), y completado por Saka, Rashford y Choupo-Moting con efectos positivos sugerentes (probabilidad posterior $\geq 0,83$). Los *tiers*

de significatividad siguen los umbrales del trabajo: *Sig_pressure_clutch* para probabilidad $\geq 0,95$, *Inconclusive* en otro caso. La columna *Elite* identifica al jugador como *top-10* del *bucket*.

Tabla D.3. *Top pressure-clutch* del *bucket* atacante (ATA).

#	Jugador	Sel	Pos	Pressure	IC80 lo	IC80 hi	Tier
1	Kylian Mbappé	FRA	LW	+0,110	+0,029	+0,193	<i>Sig</i>
2	Bukayo Saka	ENG	RW	+0,051	−0,009	+0,116	<i>Sig</i>
3	Marcus Rashford	ENG	LW	+0,050	−0,003	+0,110	<i>Sig</i>
4	Eric Maxim Choupo-Moting	CMR	CF	+0,042	−0,009	+0,101	Inconcl.
5	Rafael Leão	POR	LW	+0,037	−0,015	+0,093	Inconcl.
6	Richarlison	BRA	CF	+0,028	−0,024	+0,084	Inconcl.
7	Dušan Vlahović	SRB	CF	+0,027	−0,024	+0,081	Inconcl.
8	Gonçalo Ramos	POR	CF	+0,026	−0,024	+0,077	Inconcl.

D.4. Huella *clutch* colectiva por selección

La tabla D.4 reporta las ocho selecciones con mayor huella *clutch* colectiva agregada como promedio del índice Remontador sobre todos los jugadores del bloque. Las magnitudes son deliberadamente pequeñas en valor absoluto —el agregado *leave-one-out* centra el delta colectivo en cero por construcción—, pero el orden es informativo: Francia, Inglaterra y Croacia, las tres selecciones que más lejos llegaron en la eliminatoria, encabezan el ranking junto con Ecuador.

Tabla D.4. Huella *clutch* colectiva por selección (*top-8*).

Selección	<i>n</i> jugadores	Remontador medio	Cerrojo medio
Francia	19	+0,00039	−0,00047
Ecuador	15	+0,00036	+0,00015
Inglaterra	18	+0,00035	+0,00047
Arabia Saudí	16	+0,00032	+0,00010
Croacia	19	+0,00028	+0,00011
Alemania	17	+0,00028	−0,00060
Uruguay	11	+0,00022	+0,00022
Serbia	15	+0,00020	+0,00034

Las cuatro tablas aquí reportadas, junto con la tabla canónica del CCV y los *top-10* por posición granular disponibles en el repositorio público, constituyen el *output scout-facing* final del *pipeline*.

E Nota técnica: espejo del tracking en prórroga

Este anexo documenta una inconsistencia detectada en una parte del corpus PFF FC del Mundial Qatar 2022 entre el *frame* de tracking y el de *eventing* durante los períodos de prórroga (P3 y P4) y la corrección automática aplicada en el preprocesado.

E.1. Naturaleza de la inconsistencia

En una parte de los partidos del torneo, el *frame* de tracking entregado por PFF FC durante los períodos de prórroga (período 3, primera parte de la prórroga; período 4, segunda parte) está rotado 180° respecto al *frame* del *eventing* del mismo instante. Es decir: el vector de posiciones (x, y) de los jugadores en el tracking aparece como $(-x, -y)$ comparado con el sistema de coordenadas que el *eventing* utiliza para registrar la dirección de ataque de cada equipo. La inconsistencia es consistente con la convención de algunos proveedores de tracking de mantener la cámara orientada hacia el mismo banderín durante la totalidad del partido, mientras que el *eventing* alterna la dirección de ataque por equipo a cada cambio de período.

La inconsistencia no es universal en el corpus: afecta a una parte de los partidos con prórroga pero no a todos. La verificación manual en los partidos del torneo con prórroga ha identificado el patrón en la final Argentina-Francia (`pff_match_id` 10517) y en Japón-Croacia (`pff_match_id` 10506), y ha confirmado su ausencia en Marruecos-España (`pff_match_id` 10508). La detección caso a caso es la estrategia operativa adecuada.

E.2. Mecanismo de detección automática

El preprocesado detecta la inconsistencia automáticamente comparando, en el *frame* de tracking inmediatamente posterior a la transición de período, dos referencias independientes: la dirección de ataque del equipo en posesión registrada en el *eventing* del primer evento del nuevo período, y la posición del portero del equipo defensor en el *frame* de tracking correspondiente. Si las dos referencias son consistentes, el tracking se acepta tal cual; si son opuestas, el *pipeline* aplica una des-rotación de 180° ($x' = -x$, $y' = -y$) a todos los *frames* de los períodos afectados antes de cualquier cálculo posterior. La detección es silenciosa y produce un *flag per-partido* que documenta la corrección aplicada.

E.3. Ámbito de aplicación de la corrección

La corrección se aplica en todas las capas del *pipeline* que mezclan coordenadas del tracking con la dirección de ataque del equipo: la estimación del OBSO y C-OBSO en el canal *off-ball*, la atribución al defensor más cercano al balón en el canal defensivo y la superficie de *pitch control* sobre la que se ilustra el caso de Mbappé en la figura 5.2 del capítulo 5. Las capas que utilizan métricas invariantes a rotación —el cálculo de velocidades, distancias y *sprints* del canal físico, y los descriptores escalares de la identificación de *shocks*— no se ven afectadas por la inconsistencia y operan sobre el tracking crudo sin des-rotación.

La sincronización entre el *frame* de tracking y el evento correspondiente se realiza mediante el campo `start_frame` del *eventing*, no mediante el reloj de juego `periodGameClockTime`, que en algunos partidos del corpus deriva por unas décimas de segundo durante la prórroga y produciría desalineamientos sistemáticos en los cálculos *frame-level*.

F Repositorio público del proyecto

El desarrollo completo del trabajo —código fuente, datos derivados versionados, notebooks de regeneración, figuras y documento L^AT_EX— está disponible públicamente en el repositorio <https://github.com/jaime-oriol/CCV>. El lector puede inspeccionar el *pipeline end-to-end* sin restricciones de acceso y reproducir todos los resultados reportados en esta memoria.

F.1. Qué contiene el repositorio

El repositorio recoge las cinco capas del trabajo. La capa de código agrupa la implementación de las seis fases del *pipeline* (`src/`), desde la extracción a parquet hasta el ensamblaje de la tabla *scout-facing* final. La capa de datos derivados (`data/parquet/derived/`) contiene los *caches* intermedios versionados de las seis fases del *pipeline*; los datos brutos PFF FC, Wyscout y StatsBomb no se incluyen en el repositorio por su tamaño y por las cláusulas de uso de los proveedores, pero los *loaders* (`M01`, `M02`) documentan cómo obtenerlos. La capa de *outputs* (`outputs/`) contiene la tabla canónica del CCV (`ccv_table.parquet`, 511 jugadores $\times$ 299 columnas) y las cuatro tablas auxiliares *scout-facing*, junto con las figuras (`outputs/viz/`) y los activos visuales (`outputs/assets/`). La capa de notebooks (`notebooks/`) incluye los cuadernos de regeneración del *pipeline* completo y del modelo CATE NUTS HMC en GPU. La capa de documento (`TFM/doc/`) contiene esta memoria en formato L^AT_EX con su bibliografía `biber` y los *scripts* de compilación.

F.2. Cómo reproducir el trabajo

El repositorio incluye un *script* orquestador (`run_pipeline.sh`) que ejecuta las seis fases en orden DAG con detección automática de núcleos disponibles y GPU. Sobre los *caches* versionados, la ejecución completa es de orden de minutos por el reaprovechamiento de los resultados intermedios. La regeneración desde cero (sin *caches*) requiere los corpus brutos PFF FC, Wyscout 2017/18 y StatsBomb *open data* y se documenta en el `README.md` del repositorio. Las dependencias de Python (versión 3.12, gestionada con `venv`) están listadas en el `README.md` junto con sus versiones exactas para reproducibilidad numérica.

F.3. Licencia y acceso

El repositorio es público y se distribuye sin restricciones para uso académico y de investigación. Los datos brutos PFF FC, Wyscout y StatsBomb mantienen las licencias de uso de sus respectivos proveedores y no se redistribuyen a través del repositorio. La

contribución original del trabajo —marco CCV, código de *pipeline*, figuras, documento— queda disponible para extensión y replicación por cualquier persona interesada.